浙江省大学生
人工智能竞赛
AI 赋能未来

中国移动杯·第二届
浙江省大学生人工智能竞赛

揭榜挂帅赛报告



- ☐ 面向浙江文旅传播的AIGC城市短视频自动生成系统
- ☐ 多模态K12人工智能通识课教学助手对话智能体
- ☐ 四足机器人复杂场景中的综合应用
- ☐ 基于国产信创开源鸿蒙 AI+边缘智能应用系统设计
- ☐ 院校智能辅助场景基于AI Coding或OpenClaw引擎规范
- ☑ 文旅智能辅助场景基于AI Coding或OpenClaw引擎规范
- ☐ 基于面向智慧零售的可控自主服务机器人研发与应用
- ☐ 工业图像异常检测与定位算法挑战赛
- ☐ 基于图像识别的大田农作物病虫害智能检测与预警系统
- ☐ 纺织多模态有监督质量检测算法挑战赛
- ☐ 大口径供水管网安全风险智能评估与决策

队伍名：太帅了我们不队



目 录

第 1 章　摘要　3

第 2 章　项目背景与痛点分析　5

第 3 章　需求分析与目标用户　6

第 4 章　系统总体设计　7

第 5 章　核心功能实现①：个性化行程规划　13

第 6 章　营销素材、文创名片与生图计费　14

第 7 章　数据来源管理与反幻觉机制　16

第 8 章　长对话上下文管理与溢出兜底　18

第 9 章　对话工程与 Agent 能力分层　20

第 10 章　异常处理设计　22

第 11 章　测试与效果对比　23

第 12 章　部署与运行说明　25

第 13 章　AI Coding 开发实践　26

第 14 章　运行成本与延迟实测　28

第 15 章　商业价值与社会价值　30

第 16 章　已知限制与未来展望　32

结语与关键数字回顾　34

第 1 章　摘要

本报告给出「智旅灵犀」文旅全场景智能辅助系统（v2.2.0）的设计与实现。系统针对文旅行业景区、酒店、餐饮核心业态中的 **消费体验同质化、客源转化效率低、产品创新迭代慢**三大痛点，以 Flask + waitress 后端 + 无框架单页前端 + 国产大模型 API 的组合， 通过轻量化智能 Skill 协同实现智能咨询应答、个性化行程规划、营销内容生成、文创产品赋能与客源精准匹配五大核心场景； 并以「画像驱动的行程规划」与「营销素材生成 + 文创数字名片」为两条主线，不做功能堆叠。

系统建立数据来源四级分级标注与三道反幻觉闸口，为长对话建立基于 token 预算的上下文管理、溢出折叠与持久化兜底； 对话链路支持中途停止生成、重新生成与编辑重发、多会话并行管理、答复点赞 / 点踩落库与知识库检索出处可见； 生图侧加入参数指纹复用，同一张图不再付第二次钱。运维面板 `/admin` 把模型用量、上下文缓存命中率、 生图张数与复用率、答复质量规则指标、Agent 模块「已接线 / 建好未接线」全部如实分开呈现。

全部效果数据严格区分【实测】与【估算】/【预期】并标注来源与复现命令；第 16 章逐条列出已知限制、 影响范围与处置状态，已修复的附回归项，未修复的不掩盖。

全文按「问题 → 设计 → 实现 → 证据 → 边界」推进：第 2 至 4 章交代为什么做与整体结构，第 5 至 9 章是两条主线与三项支撑能力的实现细节， 第 10 至 14 章给出异常、测试、部署与成本的实测口径，第 15 至 16 章把价值主张与没做到的部分分列。 三条约定贯穿全文：任何数字都要能回答「从哪来、怎么复现」；任何降级都不静默吞掉而是计数进面板； 任何能力描述以请求路径为准，不以代码写过为准。

表 1-1　核心指标速览（数值取自源码统计、/api/health 与实测记录） 实测

指标	数值	性质与说明
REST 唯一路径 / 路由声明	85 / 91	源码统计（server/ 全量 @app.route，6 条路径按方法拆成两个函数分别注册）
方法注册次数	93	GET 43 / POST 42 / PUT 4 / DELETE 4
数据 / 工具插件	7 个	BasePlugin + PluginRegistry，按用户意图自动触发
指标	**数值**	**性质与说明**
Skill（OpenClaw 式规范）	3 个	tourism-advisor / tourism-marketing / smart-matching
客群画像	6 类	family_young / gen_z / couple / senior / business / team_building
SQLite 数据表	17 张	统计 server/database.py 建表语句；数据只存本机
回归测试	36 文件 / 1716 项	【实测】`python run_tests.py` → 0 失败（2026-10-05 18:37 实测）
3 天个性化行程生成	30–60s	【实测】含实时天气 / 票价拉取；缓存后 10–20s
营销文案生成	10–30s	【实测】单内容框一次成文；实测总耗时 6.66s

指标	数值	性质与说明
Seedream 概念海报	≈16s/张	【实测】输出 1MB 级 JPEG，按魔数落盘
上下文预算 CTX_BUDGET	24000 tokens	可环境变量覆盖；CJK 每字≈1 token 保守估算
长对话输入缓存命中	37.3%	【实测】4 场景 10,282 输入 token 中 3,840 命中上游上下文缓存
Agent 能力分层	3 已接线 / 11 未接线	【实测】运维面板如实分开，未接线不进请求路径
敏感信息 / 学校信息扫描	0 / 0	【实测】清洁提交包自检 0 残留、红线 0 命中

图 1-1 工程规模一览（数值取自源码逐文件行数统计） 实测

91
路由声明 @app.route

85
唯一 REST 路径

7
数据 / 工具插件

3
OpenClaw 式 Skill

6
客群画像

17
SQLite 数据表

4 + 4
核心 / 可选依赖（requirements 共 8 项）

36 / 1716
测试文件 / 测试项，0 失败

30,005
server/ Python 行数（含测试 9,689 行）

卡片数值直接取自源码统计脚本，不做示意缩放。最大单文件为 server/app.py（7,684 行）与 dashboard/index.html（10,440 行）。

报告速览

85 / 91
唯一 REST 路径 / 路由声明

1716 项
全量回归通过，0 失败

4.5k–7.8k
长对话输入 token 有界区间

37.3%
输入 token 上下文缓存命中占比

净省 1 次
生图命中指纹复用即不发起网络请求

0 / 0
敏感信息残留 / 学校信息红线命中

能力清单与回归覆盖

新增能力	落地要点	回归覆盖
多会话管理	新建对话不再删库；会话标题 / 切换 / 改名 / 删除与历史找回入口，列表按用户隔离	test_session_management 76 项
停止生成	真停上游流并释放线程，半截答复按「可能不完整」落库	test_stream_stop 71 项
重新生成 / 编辑重发	撤回只撤「这一轮」，比对不上就一律不删，防误删历史	test_regenerate 44 项

新增能力	落地要点	回归覆盖
答复点赞 / 点踩	反馈落库 message_feedback，回放时投票状态不丢，规则指标进运维面板	test_feedback_metrics 112 项
知识库检索出处可见	每轮给出真实命中的「参考来源」，没命中不做假标注	test_rag_sources 38 项
上下文压缩可视化	占用进度条 + 到 75% 触发线自动压缩；摘要与已确认事实持久化	test_context_manager 57 项
美团结果缓存	TTL 内不重复请求；接口故障回退旧数据并标明数据时间（stale-if-error）	test_meituan_cache 114 项
成本与缓存命中量化	提示词前缀稳定化吃 DeepSeek 上下文缓存；token / 延迟逐场景成表并可导出	test_llm_usage 55 项、test_prompt_cache 42 项
生图指纹复用	同一张图不付第二次钱，出图张数 / 复用率 / 失败原因进面板	test_image_cost 71 项
稳定性与凭据治理	生产 WSGI、退避重试与备用通道、DAO 降级护栏、默认示例 Key 移出源码	test_llm_retry 57、test_dao_guard 40、test_secret_hygiene 47 项

第 2 章　项目背景与痛点分析

文旅景区、酒店、餐饮三大核心业态长期面临结构性困境。**消费体验同质化**：网络攻略与行程模板千人一面，难以适配同行人群、节奏与预算差异； **客源转化效率低**：营销素材依赖人工撰写，线下文创包装印死图文，实物无法承担获客职能； **产品创新迭代慢**：从社交平台热点出现到形成可售的产品创意，传统流程以周计，热点红利窗口往往已经关闭。

行业现有单点工具多为「通用对话 + 固定模板」，AI 未承担核心业务任务。本项目以「智能适配、创新迭代、精准创收」为目标， 把传统「人工服务、固化产品、被动经营」的运营模式重构为数据与模型驱动的新模式，痛点量化与对策见表 2-1。

三大痛点不是并列的三件事，而是一条因果链：体验同质化使游客缺少非来不可的理由，转化效率低使商家看不到门票之外的收益， 产品迭代慢使文化资源停在展示层。系统因此不做三个各管一头的独立小工具，而是用同一套画像与数据底座承接三者—— 画像驱动行程对应同质化，营销素材与数字名片对应转化，热点灵感库与文创生成对应迭代速度。 AI 是否真正承担了业务任务的判准也在此定下：产出必须落到可执行的对象上（一条能导航的路线、一张能印刷的名片、 一个能点开的购票深链），而不只是一段读起来通顺的文字。

表 2-1　三大痛点的量化现状与系统对策

痛点	现状量化	系统对策	落地证据
消费体验同质化	人工排 3 天行程 2–4 小时/份【经验估计】；攻略模板千人一面	画像驱动：6 类客群 × 节奏 × 预算；规则骨架 + LLM 成文	同城市不同画像产出可复现差异方案【实测】
客源转化效率低	营销文案人工 1–2 小时/篇【经验估计】；包装印死图文无入口	三平台差异化生成 + 合规检查；数字名片二维码印码即媒介	创建 → 扫码 → 查看链路 E2E 通过【实测】
产品创新迭代慢	热点到可售创意周期以周计	抖音实时热点 + AI 配图灵感库；12 小时滚动热点池落盘持久化	热点经二次验证后出卡，卡片带真实热度值【实测】

图 2-1　文旅行业三大痛点与系统三种重构



人工耗时基线为行业经验估计【预期】，AI 侧耗时为【实测】，见第 11、14 章；本报告不将经验基线包装成实测结论。

第 3 章　需求分析与目标用户



系统的服务对象为文旅从业者、高校学生与游客三类，核心诉求与使用场景见表 3-1。行程的差异化由六类客群画像驱动（图 3-1）： 同一城市在亲子、情侣、银发、商务等画像下产出可复现的不同方案，这是「画像驱动」卖点的实现基础。 功能建设聚焦两条核心主线（图 3-2），其余能力（对话、推荐卡片、认证隔离、运维面板）均为主线服务，避免功能堆叠稀释产品定位。

三类用户中，文旅从业者是内容的生产方与付费方，游客是体验方，高校学生是复用与实训方，界面因此分两层： 默认只暴露「提需求—拿结果」这一条路径，技术细节收在 `?debug=1` 之后。 需求是否进本期有两条硬判准：这条需求能否追到一个真实数据源，以及能否写成一条会失败的测试； 两条缺一，功能就留在待办里而不是界面上——3.3 节删掉三个空壳栏目正是这条判准执行的结果。

系统约束：本地部署 · 数据安全导出 · 界面零门槛 · 异常可兜底 · 按用户隔离数据。

表 3-1　目标用户与使用场景

用户类型	典型角色	核心诉求	主要使用场景
文旅从业者	景区运营、酒店营销、文创开发	服务效率与客源转化	代客规划行程；一键生成平台化营销文案；文创转数字名片并印码上架
高校学生	旅游管理、数字媒体、文化创意	实训与创新实践	本地部署后动手实践 AI Agent 开发、运营策略对比；Agent 模块可单独运行与复核
游客	自由行、家庭出行、银发群体	体验升级	对话式提出需求，按同行人群与节奏生成专属行程与地图导航；支持语音输入

图 3-1　六类客群画像（/api/health 实测加载 crowds_loaded） 实测



银发群体
senior · 低强度、替代路线

商务出行
business · 高效、就近通勤

团建
team_building · 协作项目、批量预订

图 3-2　两条核心主线流程（Skill 协同支撑）

主线①　画像驱动的个性化行程规划
输入约束 → 画像识别 → 规则骨架 → 实时数据 → LLM 成文 → **可执行行程 + 地图路线 + 三档预算 + 替代方案**

主线②　营销素材生成 + 文创数字名片
选平台 / 客群 → 一键生成文案 → 合规检查 → 转化为名片 → 二维码印码 → **实物即传播节点**

支撑：tourism-advisor（行程规划）· tourism-marketing（营销文案）· smart-matching（文创匹配）， 均以 SKILL.md + references + scripts 组织，可热插拔、可复核。

3.3 界面只留有数据来源的栏目

个人中心删掉了「订单 / 酒店 / 机票」三个没有真实数据源的空壳栏目，只保留三条能追到库里数据的链路：**我的行程**（itineraries 表）、**我的营销内容**（marketing_contents 表）、**我保存的攻略**（社区收藏真实落库）。 凡界面出现的字段都必须能回答「这条数据是谁写的」；这条约束同样落在第 7 章的反幻觉机制与第 14 章的计量口径上。 回归：test_profile_center 78 项、test_data_export 50 项。

第 4 章　系统总体设计

系统采用四层架构（图 4-1），追求「依赖少、链路短、可审计」。

四层的职责边界按「谁能为结果负责」划分：前端只做呈现与交互，不内置任何密钥、不自己拼数据； 后端是唯一的状态写入者，负责校验、留痕与降级；插件与 Skill 层把外部世界的不确定性包住，向里只暴露统一结构； 模型与数据层把所有可替换的东西（模型厂商、生图通道、存储位置）留在能被配置改走的地方。 前端选择零框架原生 JS 是这套取舍里代价最大的一条：单文件 10,440 行、没有构建产物，换来的是交付即双击可跑、 在评委机器上不存在依赖冲突——这个代价如实承担，用注释分区与调试分层来管理。

图 4-1　智旅灵犀四层系统架构

Web 前端层dashboard 单页 SPA · 原生 JS 零框架零构建（index.html 10,440 行，唯一外链脚本是本地 qrcode.min.js）· 高德 JS API 2.0 地图（Key 由后端 /api/map/key 下发，前端不内置任何密钥）· SSE 流式渲染与出处卡片

↓

Flask 后端层91 路由声明 / 85 唯一 REST 路径 · /api/chat · plan · marketing · creative · cards · map · auth · sessions · feedback
生产入口 waitress 多线程 WSGI（threads 默认 8，SMARTTOURISM_THREADS 可覆盖），未安装 waitress 时自动回退 Flask 内置服务器

↓

插件 + Skill + Agent 层7 插件（天气 / POI / 地图 / 美团 / 票价 / 飞猪 / 本地知识库）按意图自动触发 · 3 Skill（advisor / marketing / matching）OpenClaw 式规范 · Agent 能力库 15 模块（3 个已接入请求路径，11 个建好未接线 + 1 个仅被面板引用，分层见第 9 章）

↓

模型与数据层大模型 DeepSeek / 智谱 / 通义 / Kimi 运行期热切换 · 图片生成走火山方舟 Seedream · SQLite 本地持久化（17 张表）+ 按用户命名空间 localStorage + data/logs 与 operation_logs 全链路留痕

4.1 核心 REST 接口

表 4-1　核心 REST 接口（全量 85 个唯一路径，此处列主干）

接口	功能	说明
/api/chat	智能对话	流式输出、多轮对话、追问引导；带 regenerate / 编辑重发标记；插件按意图注入实时数据；响应含 context 压缩元数据与 sources 出处事件
/api/chat/stop	停止生成	中止上游流并释放工作线程，半截答复以「可能不完整」落库
/api/plan	行程规划	参数校验 → 规则骨架 → 实时数据注入 → LLM 成文 → 来源标注；DeepSeek 下输出上限 8192 tokens
/api/marketing	营销生成	小红书 / 公众号 / OTA 差异化文案 + 转化路径 + 合规检查；type=blog 走博客配图链路
/api/creative	文创赋能	文化元素提取 → IP 合规检查 → 产品梯度 → 包装故事 → 海报联动
接口	**功能**	**说明**
/api/cards	文创数字名片	字段白名单 + 裁剪，上限 500 条，返回短 id；保存时异步预热配图，命中指纹复用不再生图
/api/sessions*	多会话管理	列表（标题 / 条数 / 末条摘要，按用户隔离）、新建、改名、删除、历史消息与摘要读写
/api/feedback	答复点赞 / 点踩	按 answer_id 落库，可取消；回放时投票状态不丢
/api/recommend/cards	目的地推荐卡片	美团实时数据优先，高德补齐，本地知识库兜底，带购票直达与来源徽标
/api/map/*	地图服务	regeo / around / direction / ip-location / poi-search / poi-photos / key
/api/auth/*	账号与隔离	captcha / register / login / logout / me，PBKDF2 散列 + 一次性图形验证码
接口	**功能**	**说明**
/api/ark/generate	文生图	火山方舟 Seedream，支持场景专属 Key 与模型；带参数指纹复用台账
/api/memory*　/api/export/mine	记忆与数据	跨会话长期记忆写入 / 召回 / 删除；本人数据整包导出
/api/health　/api/admin/ops	健康与运维	status、版本、配置完整度、已加载插件 / Skill / 客群；面板给用量、命中率、降级计数与接线状态

4.2 插件、Skill、数据层与模型

插件与 Skill 层：7 个数据 / 工具插件统一继承 BasePlugin 并在 PluginRegistry 注册，由 `registry.auto_trigger` 按用户意图自动触发；tourism-advisor、tourism-marketing、smart-matching 三个 Skill 按 OpenClaw 式规范组织（SKILL.md + references + scripts）。/api/health 实测返回 `plugins_loaded: 7`、`plugins_configured: 6`、3 个 skills_loaded、6 个 crowds_loaded。

数据层：SQLite 本地持久化（17 张表，见表 4-2）+ 按用户命名空间的 localStorage + data/logs 与 operation_logs 运行留痕，数据只存本机，可用 `/api/export/mine` 一键整包导出。

大模型支持 DeepSeek / 智谱 / 通义 / Kimi 运行期热切换（默认 deepseek-chat，`/api/providers` 与 `/api/config` 读写）；图片生成统一走火山方舟 Seedream，支持场景专属 Key 与模型，并带参数自适应重试与「场景 Key 欠费回落共享 Key」两级容错。发送层另加退避重试与备用通道（见第 10 章）。依赖清单与轻量约束见表 4-3。

表 4-2　SQLite 数据表分组（统计自 server/database.py 建表语句） 实测

分组	表	作用
账号与令牌	users · user_store · auth_tokens	PBKDF2 口令散列、登录令牌与会话状态（TTL 7 天）
对话与记忆	sessions · messages · session_state · memories · message_feedback	多会话历史、滚动摘要与已折叠轮数、跨会话长期记忆、答复点赞 / 点踩
业务产出	itineraries · marketing_contents · xhs_notes · imported_sources	行程收藏、营销内容、社区攻略与外部导入知识源
出行数据	travel_cities · travel_pois	城市与 POI 缓存，支撑推荐卡片
商业与留痕	coupon_claims · ark_image_cache · operation_logs	优惠券领取、生图参数指纹复用台账、全链路操作留痕

表 4-3　依赖清单（requirements.txt 共 8 项：4 核心 + 4 可选） 实测

依赖	用途	必需性	未安装行为
flask >=3.0	Web 后端框架	核心	—
flask-cors >=4.0	跨域支持	核心	—
requests >=2.28	调用大模型 / 第三方 API	核心	—
waitress >=2.1	生产级多线程 WSGI	核心（生产）	自动回退 Flask 内置服务器，服务仍可启动
gradio >=4.0	演示前端	可选	不影响 Flask 服务启动
chromadb >=0.5	RAG 向量检索	可选	自动退化为关键词检索
beautifulsoup4 >=4.12	外部导入网页解析	可选	导入功能降级
faster-whisper >=1.0	本地离线语音识别	可选	Web Speech 不可用时自动降级

轻量约束是显式设计目标：去掉 waitress 后 3 个依赖即可完整起服务（waitress 缺失只是回退内置服务器，不是崩溃），依赖口径按 requirements.txt 逐行标注为「4 核心 + 4 可选，最小启动集 3 个」，不用一个数字含糊过去。上下文管理、语义缓存、长期记忆三个模块亦零第三方依赖（不引入 tiktoken，也不把 LangChain / 向量库当硬依赖）。

4.3 一次行程规划请求的完整链路

图 4-1　一次行程规划请求的完整链路（第 5 章展开各环节要点）

① **前端表单 / 对话提需求**目的地 · 天数 · 预算 · 同行人群 · 路线节奏 · 兴趣偏好

↓

② **参数完整性校验**缺目的地 / 天数 / 同行关系 → 返回澄清话术，不臆造

4.4 接口规模与模块分布 实测

↓

③ **规则骨架生成**plan_generator 先按规则产出每日主题、消费点与三档预算框架

↓

④ **实时数据注入**高德天气与 POI + 美团门票 / 房价（TTL 缓存命中，故障回退旧数据并标明数据时间），插件按意图自动触发

↓

⑤ **LLM 按模块成文**SSE 流式输出，十一模块模板约束，clean_llm_output 规整；提示词头部逐字稳定以吃上游上下文缓存

↓

⑥ **来源标注 + 分层渲染 + 留痕**validation 分级标注，地图自动画线；operation_logs 记 action / skill / cost / success

对 server/ 全部 @app.route 声明逐条统计：**91 个路由声明、85 个唯一路径、93 次方法注册**（GET 43 / POST 42 / PUT 4 / DELETE 4）。6 条路径按方法拆成两个函数分别注册（/api/config、/api/xhs/notes、/api/sessions、/api/sessions/<id>、/api/itineraries/<id>、/api/ark/config），所以方法注册 93 大于唯一路径 85。按六大模块分组见表 4-4。

表 4-4　模块分组与路径统计【实测】

模块分组	唯一路径	GET	POST	PUT / DELETE	代表接口
账号与用户数据	27	13	11	3 / 4	/api/auth/* · /api/sessions* · /api/itineraries · /api/memory*
推荐与商业	17	10	9	—	/api/recommend/cards · /api/cards · /api/shop/* · /api/xhs/notes
系统与插件运维	14	9	6	1 / —	/api/health · /api/admin/ops · /api/plugins/* · /api/ark/*
地图与出行	13	6	7	—	/api/map/* · /api/travel/* · /api/network-info
核心业务	10	1	9	—	/api/chat · /api/chat/stop · /api/plan · /api/marketing · /api/feedback

统计脚本只读，不连库不出网；路径归组按段边界匹配（/api/map 与 /api/map/key 同组），85 条路径 0 条未归类。

模块分组	唯一路径	GET	POST	PUT / DELETE	代表接口
前端页面与其他	4	4	—	—	/ · /m · /map · /digital-card.html
合计	**85**	**43**	**42**	**4 / 4**	91 个路由声明，方法注册共 93 次

4.5 代码规模与工程留痕 实测

统计项	数值	口径
server/ Python 文件与行数	63 个文件 · 30,005 行	递归统计 *.py（不含 __pycache__）；其中测试 9,689 行，业务实现约 20,316 行；最大单文件 app.py 7,684 行
前端单页	dashboard/index.html 10,440 行	零框架，唯一外链为本地 qrcode.min.js
插件 / Skill / 数据表	7 · 3 · 17	plugins/ 统一继承 BasePlugin；skills/ 按 SKILL.md + references + scripts；SQLite 17 张表

图 4-2　85 个路径的模块分布 实测

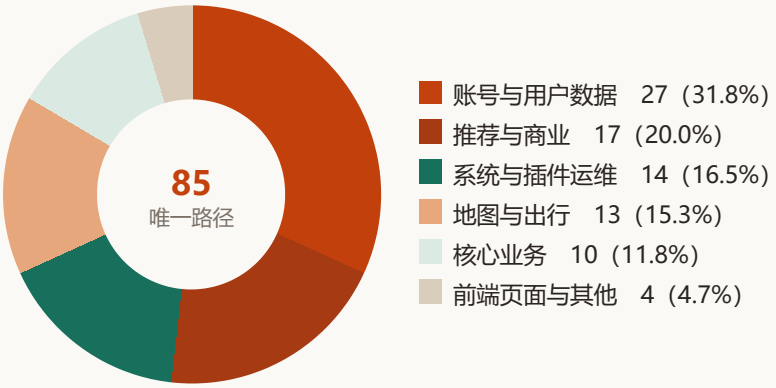
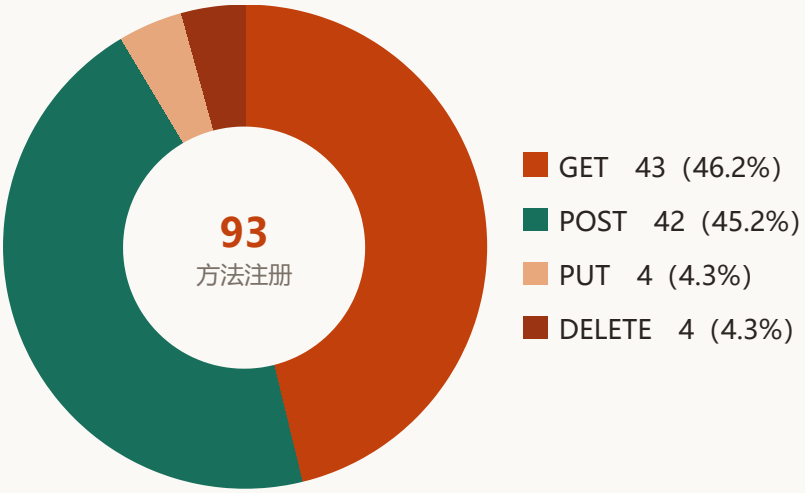
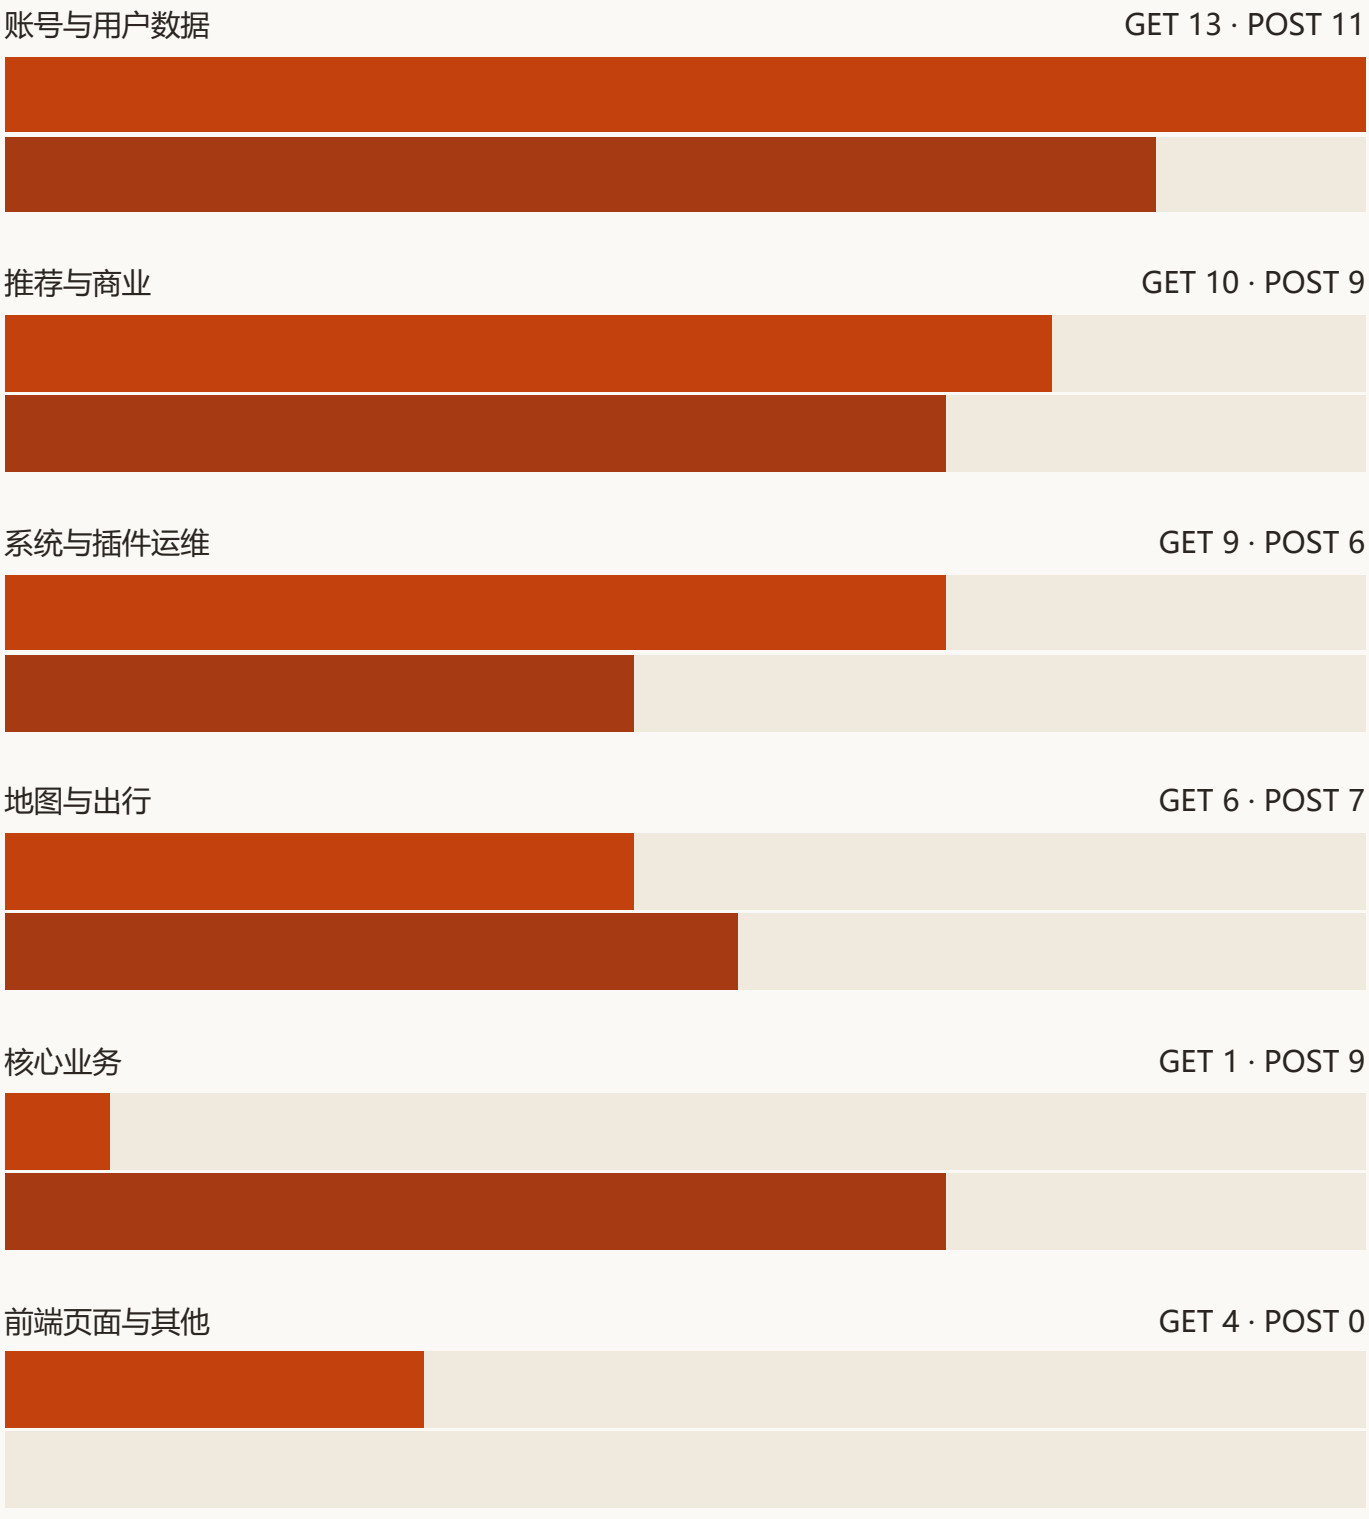


图 4-3　HTTP 方法分布（93 次方法注册） 实测



橙 = GET，绿 = POST。读图：GET 43 / POST 42 均衡双主力，核心业务几乎全是 POST（生成类请求）； PUT / DELETE 集中在账号与运维模块（会话改名与删除、行程更新、长期记忆删除）。 方法合计 93 大于唯一路径 85，因为部分路径同时注册了 GET 与 POST。

图 4-4　GET vs POST 分组对比（条形按 GET 最大值 13 定标）【实测】



第 5 章　核心功能实现①：个性化行程规划

行程规划（链路见图 4-1）的要点是**规则先行、模型成文、数据可溯**：缺参先澄清、不臆造不瞎编；plan_generator 按规则产出每日主题、消费点与预算框架； 注入天气、高德 POI、美团票价等实时数据后交由模型按固定模块成文（输出经 clean_llm_output 规整），最后标注来源并双层渲染。 输出包含十一个模块（图 5-1），「思考与依据」折叠层置于开头，浏览层按一至五重新编号。

规则与模型的分工边界是可测性：三档预算的元区间、七类客群的景点与节奏侧重、每日安排的字段结构都由 `plan_generator` 以数据形式产出，能被单测逐条断言；模型只负责把这些骨架组织成有理由的自然语言。 实时数据采集走天气、门票、房价三线并行，任一条取不到时返回的是「[XX 数据不可用：原因]」这样的显式占位而不是静默省略—— 这一条决定了模型不会把缺失当成已知去编。整条链路因此两头都可查：骨架对不对看测试，成文好不好看来源标注。

图 5-1　行程规划输出的十一个模块（规则骨架 + LLM 成文）



「思考与依据」折叠层置于输出开头独立呈现推理依据；浏览层按一~五重新编号，只保留用户要执行的内容。

带 * 为硬性必填三要素。校验先于生成：这是「不臆造不瞎编」反幻觉约定的第一道闸口（见第 7 章）。

地图侧在行程生成后自动绘制路线，支持驾车、公交、步行、骑行与地铁，支持高铁 / 飞机跨城方案一键查询；多人同行的偏好冲突由提示词高优先级规则与固定输出模块「五、多人偏好平衡说明」承接，要求逐人写明被满足在哪里、 共同满意点在哪里——这是规则与模板层的约束，不是独立求解算法，边界如实记入第 16 章。

表 5-1　行程规划输入参数与完整性校验

输入参数	示例	校验与缺失行为
目的地 *	洛阳 / 3 天	缺失 → 返回澄清话术，不臆造
天数 *	3 天	缺失 → 返回澄清话术，不臆造
同行关系 *	亲子 / 情侣 / 银发 / 团建	缺失 → 返回澄清话术，不臆造
路线节奏	松弛慢游 / 打卡紧凑	缺省按客群画像默认值

输入参数	示例	校验与缺失行为
预算档位	经济 / 舒适 / 豪华三档	缺省产出三档预算方案
兴趣偏好	博物馆 / 美食 / 夜景 / 非遗	缺省按客群画像默认偏好
消费点数据	门票价 / 房价 / 开放时间	查无可靠来源 → 标注「暂未核实」并给替代建议

输出长度：单次请求 max_tokens 由 API_CONFIG 统一控制（默认 4096）。 长行程需要的 `plan→8192` 提升分支实测已生效 —— `/api/plan` 的两处调用均显式传 `skill_name="plan"`（app.py:3422 流式、app.py:3425 非流式）， 命中 `skill_max_tokens = {"plan": 8192}`，十一模块长行程尾部被截断的风险解除；该提升按供应商限定为 DeepSeek，其它供应商保持原配置。

5.2 同一轮里的两次模型调用

一轮行程规划除正文外还有一次「预生成思考」（非流式），用来先把依据、冲突与假设写清楚。这意味着**一次用户等待实际花了两次调用的钱。** 第 14 章的计量按场景把两次都算进去了（咨询 2 次、行程 2 次、改需求 2 次、营销 1 次），而不是只报一次 —— 这既是成本诚实，也是解释「为什么首字要等 40s」的必要信息。

第 6 章　核心功能实现②：营销素材、文创数字名片与生图计费

营销生成：/api/marketing 的差异化发生在两个维度上（表 6-1）：**内容类型**决定篇幅与硬性结构， **投放渠道**只影响语感微调，两者不是一回事——把「平台」当成模板来写会让公众号推文被压成 120 字。 结果在单一内容框完整呈现，支持一键复制与「转化为数字名片」。实测单次生成约 10–30s； 成本实测里营销场景总耗时 6.66s、首字 1.21s、输出 1,227 字。

表 6-1　营销生成：五类内容规格与共用红线 实测

内容类型	篇幅约束	硬性输出结构	语感要求
social 种草文案	全文 ≤120 字	噱头主标题 + 一句传播语 + 三个亮点 + 行动号召 + 3~5 个话题标签	口语化、有情绪，像朋友安利而非官方通稿
article 公众号推文	600~900 字	标题 + 导语 + 三个小节（是什么 / 好在哪 / 怎么玩）+ 结尾引导	叙事完整、信息密度高，适合深度阅读与转发
video_script 分镜脚本	15~30 秒 · 4~6 镜	前 3 秒钩子 + 每镜「时长 | 画面 | 口播 | 字幕花字」+ 结尾 CTA	镜头语言具体可拍，口播短句有节奏
poster 海报文案	全文 ≤100 字	主标题 + 副标题 + 核心 slogan + 卖点三条 + 视觉建议	字字精炼、留白感强，每句都能直接排版上海报
event 活动策划	400~600 字	活动名称 + 主题 slogan + 环节流程 + 活动亮点 + 宣传与转化	结构清晰可执行，突出参与感与传播点
共用红线（全类型）	—	不得编造价格与数据；不得使用绝对化极限词（最 / 第一 / 顶级 / 全网唯一）；不得虚假承诺	禁 Markdown 表格与分隔线，除规定结构外不输出解释或自检

文创不走这条链路：界面上的「文创产品概念」选项在营销侧没有独立规格，会按种草文案的结构出稿； 文创的完整流程（文化元素提取 → IP 合规检查 → 产品梯度 → 包装故事）走 `/api/creative`， 文案约 200 字收口，「数字名片」入口也只在文创品类出现；博客类（ `type=blog` ）走配图链路。 合规检查里的「绝对化用语」命中会进运维面板的答复质量指标，作为待观察项而不是通过率数字（见第 16 章）。

文创赋能：/api/creative 使用独立 Prompt 流程（文化元素提取 → IP 合规检查，覆盖文物 / 遗址、宗教 / 民族、名人 / 非遗、商标 / 品牌、地图 / 国旗等风险 → 产品梯度设计 → 包装故事 → 海报联动提示词），概念海报由 Seedream 生成（实测约 16s/张、1MB 级 JPEG）。 数字名片承担「实物印码即媒介」的转化职能，参数与信息分层见表 6-2：应用内只展示「噱头」，扫码打开的 H5 名片承载完整故事与购买跳转； 保存时后端异步预热配图（`_warm_card_image`），避免顾客扫码等待 40s 以上。

表 6-2　文创数字名片：系统参数与信息分层

项	取值 / 机制	说明
存储上限	500 条	超限返回 507
短 id	c + 10 位十六进制	正则校验，用于 H5 短链
写入防护	字段白名单 + 逐字段 _clip 裁剪	防超长字段污染
项	**取值 / 机制**	**说明**
应用内（扫码前）	传播语 + 3 亮点 + 二维码	只展示「噱头」，制造想扫的动机
H5 名片（扫码后）	深入了解 / 文化背景 / 设计理念 / 购买跳转	完整故事与转化入口
core_only 模式	≤700 字 · 五模块	从灵感种子直达名片内容
配图预热	_warm_card_image 异步生图	避免顾客扫码等待 40s+；命中指纹复用则不再生图
印刷传播	二维码可下载印刷	包装 / 展架即传播节点

6.3 生图指纹复用：同一张图不付第二次钱 实测

火山方舟 Seedream 按张计费，博客三张配图与名片预热配图在同一批次里高度重复。为避免「同样参数再问一次就再付一次钱」， 生图侧加了一层参数指纹复用：把 `model / size / prompt / negative_prompt / scene / img_num / watermark` 规范化后取 sha256 作指纹，命中 `ark_image_cache` 表里已落盘的图片就直接复用， **命中即不发起网络请求 —— 那一次是净省。**缓存 DAO 用 `@guarded()` 包裹：读缓存失败只当没命中，不阻断出图。

表 6-3　生图计量口径与配套修复 实测

项	说明
计费口径	一次出图请求 = 一张计费图；面板记 requests / reused / saved_requests / reuse_rate，失败仍算已发出的请求（上游是否计费不由我们决定）
金额口径	未配 `SMARTTOURISM_PRICE_ARK_PER_IMAGE` 时只报张数不报钱，不凭空造价
跨重启	进程计数重启清零，库里的指纹与图片累计跨重启保留；面板文案写明哪一项是哪种
超时错位修复	后端生图 timeout=150s、拉图 60s，前端 abort 提到 215s：此前前端先 abort，出现「上游已出图并已计费、本地拿不到图」，现按后端真实耗时对齐

第 7 章　数据来源管理与反幻觉机制

项	说明
失败留痕	fail_reasons 按原因分类计数（含账户欠费 AccountOverdueError），失败回退占位图并可重试，不假称成功
回归覆盖	server/test_image_cost.py 71 项：指纹稳定性、命中不发网络、失败计数与超时对齐全部断言

系统数据按可靠性分四层接入，优先级自上而下递减（图 7-1）：美团实时数据（门票价格、商户评分、dpurl.cn 购票深链）→ 高德 Web 服务（POI、天气、地图与路线）→ 抖音实时热点（经 TikHub 进入灵感库）→ 本地知识库仅作最后兜底，且只在库内已有真实数据的城市生效。

图 7-1　四层数据来源与兜底关系（优先级自上而下递减）

① **美团实时数据**门票价格、商户评分、dpurl.cn 购票深链

↓ 不可用 / 超时 / 无结果

② **高德 Web 服务**POI 地址 / 电话 / 图片、天气、地图与路线规划

↓ 无覆盖

③ **抖音实时热点**经 TikHub 接口进入灵感库与门户展示，卡片带真实热度值

↓ 全部不可用

④ **本地知识库（兜底）**仅在前述不可用且库内确有该城市数据时生效

取不到图片时置 image_missing 走占位并显示「暂无图片」，取不到价格时标注「暂未核实」—— 全链路绝不编造图片与价格；每次 LLM 调用均留痕（data/logs + operation_logs）可回溯。

表 7-1　反幻觉：来源分级标注字段与前端表现

字段	取值	前端表现 / 行为
source	meituan / amap / local_knowledge	卡片来源徽标，标明数据出处
source_detail	具体接口与查询串	debug 模式可展开核验
image_from	美团实拍 → 高德 POI 图补齐	图片按优先级取用
image_missing	两源皆无图片时置位	显示「暂无图片」占位，绝不编造图片
validation	非流式随响应返回 / 流式 SSE 事件	无法核实的信息标注「暂未核实」并给替代建议
留痕	data/logs + operation_logs	每次 LLM 调用可回溯核验（action / skill / cost / success）

7.2 三道闸口与「降级不静默」

第一道 · 输入闸口：必填三要素缺失即返回澄清话术，先于任何生成（见表 5-1）。

第二道 · 数据闸口：价格 / 图片 / 开放时间只认实时接口与库内真实数据，缺失走 image_missing 与「暂未核实」。

第三道 · 输出闸口：模型输出经 validation 校验（绝对化用语、无来源价格、编造图片链接），问题以 SSE 事件如实下发。

三道闸口不合并成一道，是因为它们挡住的是三种来源不同的错误：输入闸口挡用户的省略，数据闸口挡上游的缺失， 输出闸口挡模型的编造；三者的处置手段也因此不同——前者追问、中者占位、后者告警。 输出闸口刻意只做校验与如实下发，不自动改写文本：在没有真值可对照时，把一句正常表述改成同义说法既可能改错， 也剥夺了用户自己判断的机会，所以问题回给前端与面板，改不改由人决定。

校验环节本身也可能出错，因此它**降级不静默**：按环节兜住、计数聚合进面板 `validation` （runs / issues / degraded_runs / by_stage / last_error），运维面板能看到「哪一环掉过几次」， 而不是把降级吞成一次正常通过。回归：server/test_validation_degrade.py 42 项。

7.3 知识库检索出处可见 实测

本地知识库走 BM25 + 向量的混合检索。每轮答复若命中库内片段，后端下发 `sources` 事件、前端渲染「参考来源」卡片， 标题与出处可点验；**没有命中就不出标注** —— 不做「看起来有出处」的假标注。出处已从内部字段变成用户可见证据。 回归：server/test_rag_sources.py 38 项。注：混合检索模块已在请求路径接线，当前实例面板状态为 `wired_idle` （尚无请求触发索引构建时如实标注，不假称已命中）。

出处不只是「答复里的一段说明」，而是一条可回溯的链路：命中片段随答复落库（ `sources_json` ）， 回放时逐条折算成 `has_sources` ，运维面板把它聚合成「带知识库出处 N 条」，历史回看还能追溯到当时的依据。 流式答复还会先下发 `preparation` 事件，把采集耗时、本轮命中几条库内出处、是否取到实时数据在正文出现之前就摆出来—— 用户在等待阶段就能看出这条答复是「查出来的」还是「写出来的」，而不是事后自己猜。

7.4 闸口的实现代价与它管不到的部分

三道闸口都在请求路径上，实现却只用标准库的 `re` 与计数，没有为「反幻觉」引入新依赖： 输入闸口除必填三要素外还识别纠正与放弃信号（ `detect_user_conflict` ），按强度分别注入「承认偏差并重新分析」 「确认真实意思后修正」「留意补充并调整方向」的前缀，放弃信号则改为简洁收尾；输出闸口把答复与本轮插件真实数据逐项比对， 冲突作为告警下发而不阻断答复。

这条边要说清楚：规则能证明的是「这句话有没有来源、有没有踩到已知违规表达」，不能证明「这句话是对的」。 词表与正则的覆盖始终有限，因此本项目不把 `validation` 通过率当质量结论，只当可复现的过程计数——把通过率变成可用信号需要改成带上下文的判定，这一条已列在第 16 章的待办里。

第 8 章　长对话上下文管理与溢出兜底

旧实现按「固定取最近 20 条」硬截断历史，长对话带来上下文膨胀、早期硬约束（预算 / 人群 / 天数）丢失、复读与漂移三个问题。 `server/context_manager.py` 参考 Lost-in-the-Middle 、 LangChain ConversationSummaryBufferMemory 与 MemGPT 分层记忆思路， 零第三方依赖（不引入 tiktoken 与向量库），保持轻量约束。

按 token 预算而不是按条数管理历史，是这一章的核心取舍：一条 20 字的确认与一条 800 字的行程在「条数」上等价， 在上下文里却差 40 倍。「最近 4 轮无条件必保」又优先于预算本身——宁可让某一次请求短暂超预算， 也不能让对话在用户眼前断裂；两者冲突时先保连贯、再控成本，超出的部分由摘要器在下一轮收回。

图 8-1　上下文预算分配、溢出折叠与事实锚定

预算装配顺序system 提示 → 滚动摘要 → 最近 4 轮（无条件必保）→ 贪心装入更旧轮次 → 溢出则折叠

↓

折叠摘要装不下的更旧轮次交给摘要器（复用同一 chat API，压成 ≤150 字，SUMMARY_MAX_CHARS=300 硬上限）； folded 计数保证同一轮不会被二次压缩

↓

下一轮注入摘要作为第 2 条 system 消息置于前部；**事实锚定块**把已确认的目的地 / 天数 / 预算 / 人群拼在当前用户消息最前（冲突时优先采用）

表 8-1　上下文管理：参数与组装策略（server/context_manager.py）

参数	默认值	作用
CTX_BUDGET	24000 tokens	输入预算硬上限（deepseek 64K 窗口，预留输出与插件尖峰）
CTX_RECENT_ROUNDS	4	最近 N 轮无条件必保（宁可超预算也不断裂）
CTX_MEM_CAP	40	内存历史上限
CTX_COMPRESS_TRIGGER	0.75	占用到 75% 触发自动压缩，并在前端进度条显示
SUMMARY_MAX_CHARS	300	滚动摘要自身硬上限（要求压成 ≤150 字）
token 估算	CJK 每字≈1；其余 len/4	零依赖保守近似，宁可高估不超发
组装顺序	system → 摘要 → 最近 4 轮 → 贪心装入更旧轮次	装不下 → 折叠进摘要；当前用户消息永不清退
事实锚定	build_facts_block	已确认目的地 / 天数 / 预算 / 人群拼在当前消息最前，冲突时优先采用
持久化	sessions.history_summary · session_state	滚动摘要与已折叠轮数落库；已确认事实落 session_state.facts_json

全部阈值支持环境变量覆盖；摘要器复用同一 chat API，调用失败则降级为直接丢弃旧轮次并保留旧摘要，不影响主对话。

前端把这件事做成可见的：对话区常驻**上下文占用进度条**，到 75% 触发线自动压缩并给出提示 （浏览器实测发现轨道宽度随文案抖动，已固定布局）。回归：server/test_context_manager.py 57 项， 含折叠生效、当前消息不清退、持久化读回与事实锚定。

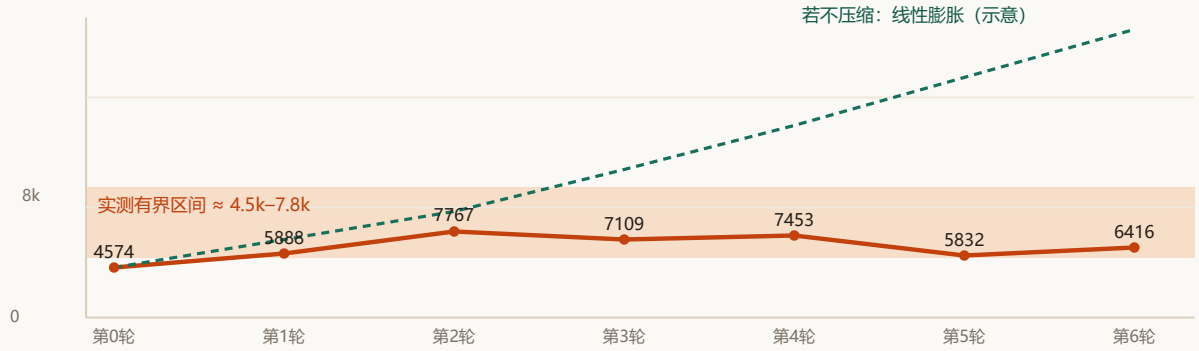
与反幻觉体系的合流点是事实锚定： `build_facts_block` 从 fact_tracker 取出本会话已确认的目的地 / 天数 / 预算 / 人群， 生成「冲突时优先采用」的提示块。上下文摘要不落内存态： 摘要与折叠轮数落 `sessions.history_summary` 与 `session_state.folded_rounds`， 内存缺失时按会话从库里读回，服务重启不会「首轮失忆」；长期记忆独立落 `memories` 表，面板 persisted=true。

8.2 溢出专项 实测

溢出专项实测的做法：以临时实例连发 7 轮长填充消息，预算压至 `CTX_BUDGET=2600` 、 必保轮次 `CTX_RECENT_ROUNDS=2` ，逐轮读 `/api/chat` 响应里的 context 元数据 （ `est_input_tokens / rounds_dropped / rounds_in_summary / summary_used` ），取值见表 8-2： 第 4 轮起触发折叠，输入 token 估算值始终被压在 4.5k–7.8k 区间，不再随轮次线性膨胀。

口径说明：这 7 轮是**一次性实测记录**（临时脚本按提交包规则以 `_` 前缀存放、不随包发布）， 因此本表可按上述方法重跑，但重跑数字会随填充文本变化；**长期锁住折叠与预算行为的是 `python server/test_context_manager.py` 的 57 项单测**（含预算贪心装入、最近 N 轮必保、摘要硬上限、事实锚定）。

图 8-2 溢出实测折线：输入 token 有界（数据取自一次性溢出运行的服务端日志）



临时实例 CTX_BUDGET=2600 / CTX_RECENT_ROUNDS=2，连发 7 轮长填充消息。 结论：第 4 轮起 rounds_dropped=1、summary_used=True，而 est_input_tokens 始终压在区间内 —— 折叠生效。 绿色虚线为「不做压缩」的示意走势，不是实测值。

表 8-2 长对话溢出专项：逐轮实测数据（一次性运行，方法见 8.2）

轮次	rounds_total	rounds_dropped	rounds_in_summary	summary_used	est_input_tokens
1	0	0	0	False	4,574
2	1	0	0	False	5,888
3	2	0	0	False	7,767
4	3	1	1	True	7,109
5	4	1	2	True	7,453
6	5	1	3	True	5,832
7	6	1	4	True	6,416

临时实例参数 CTX_BUDGET=2600 / CTX_RECENT_ROUNDS=2（为在 7 轮内逼出折叠而调小）； 生产默认 24000 / 4 轮。

第 9 章　对话工程与 Agent 能力分层

这一章交代 10 月新增的内容。它回答两件事：**一次对话要能被用户拿回、改回、停下来**； **Agent 能力要如实分开「接进了请求路径」与「建好但没接」** —— 不能把 import 过的模块说成上线的能力。

9.1 多会话：新建对话不再删库

「新建对话」最初实现是把当前会话历史清掉，用户的行程与上下文随之丢失 —— 这是最严重的一类缺陷，功能名字和真实行为不一致。 现已改成真正的多会话管理：会话列表返回标题 / 条数 / 末条摘要并按 user_id 隔离，支持新建、切换、改名与删除； 删除按 `session_id + user_id` 双条件匹配，不是本人的会话删不掉，历史找回入口常驻侧栏。 回归：server/test_session_management.py 76 项，含「新建不删库」「列表按用户隔离」「改名只动自己名下」等断言。

「停止生成」被实现为真停而不是前端遮字，原因很实际：上游流不关就仍在计费，工作线程不释放就占着 `waitress` 的 8 个坑位——一次「假装停止」在单机演示里看不出来，在并发下会立刻暴露。 已生成的半截内容照样落库并标「可能不完整」，因为它确实是用户拿到的东西，藏起来等于伪造历史。

9.2 停止生成、重新生成与编辑重发

能力	机制	诚实边界
停止生成 /api/chat/stop	真停上游流并释放工作线程，不是前端把字挡住；面板 chat_streams 记 active / cancelled / client_disconnected	半截答复按「可能不完整」落库，不伪装成完整答复
重新生成 regenerate	撤回只撤「这一轮」：先比对末条消息确属本轮，再重出	比对不上就一律不删，显式返回 nothing_to_regenerate，避免误删历史
编辑重发 edited resend	改写本轮问题后重发，同样只回收这一轮	更早轮次的历史与已确认事实保留，不连带清库
答复反馈 /api/feedback	点赞 / 点踩按 answer_id 落库 message_feedback，可取消；回放时投票状态随消息一起返回	面板 answer_quality 如实显示 voted / unvoted，没人投票就不编满意度

回归：test_stream_stop 71 项 · test_regenerate 44 项 · test_feedback_metrics 112 项 · test_session_management 76 项。

9.3 答复质量：把规则指标放进面板，而不是放进自我评价

每条落库的答复跑一组规则（无违禁词、来源标注、结构完整、无编造价格等），结果聚合进 `/api/admin/ops` 的 `answer_quality`：按 up / down / unvoted 分桶，并保留**失败样本**（问题原文 + 命中的规则）。 当前实例里能看到形如 `no_banned_terms: 命中违规词: ['第一']` 的样本 —— 规则把「第一天」这类正常表述也判成违规， 这是**已知误报**，如实列进第 16 章，而不是调松阈值凑一个好看的通过率。

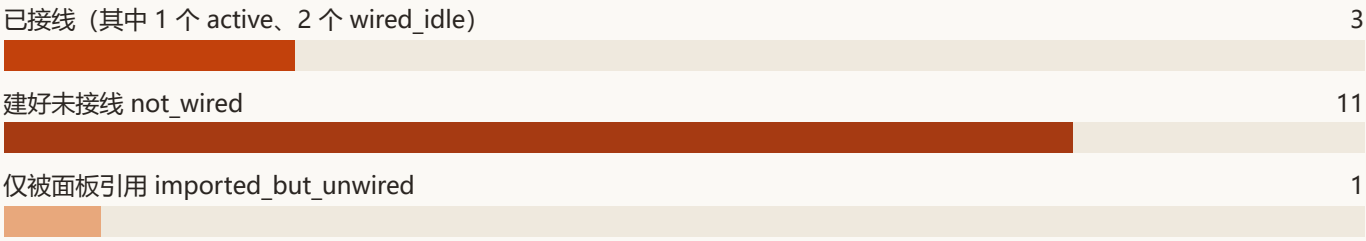
9.4 Agent 能力分层：3 已接线 / 11 未接线 实测

Agent 能力库共 15 个模块。运维面板把它们按 `wired`（进入 /api/chat 请求路径）与 `unwired`（建好但不在请求路径）如实分开，并逐条给出未接的原因；下表给出分层，图 9-1 给面板实测计数。

为了让「未接线」不等于「没做完」，这 11 个模块做成一条命令可复现的离线运行记录： `python server/agent_offline_demo.py` → **11 ok / 0 failed**（2026-10-05 18:38 实测）， 逐模块打印输入、输出与断言，详见仓库内《Agent模块离线运行记录.md》。**报告与答辩均不宣称这些模块在线服务。**

状态	模块	说明
已接线 • active	memory	跨会话长期记忆：每轮召回注入 + 答复后后台沉淀，面板 persisted=true 实测生效
已接线 • wired_idle	semantic_cache · rag_hybrid	代码在请求路径上，但当前实例还没有请求触发装配（语义缓存 TTL 900s / 相似度阈值 0.92）；状态如实标 idle，不假称已命中
未接线 • not_wired	graph · multi_agent · hitl · tools · mcp_server · model_router · guardrails · tracing · structured_output · graphrag	LangGraph StateGraph 编排（含 SQLite checkpointer）、规划 / 执行 / 审校多 Agent、HITL 中断确认、Tool / Function-Calling 抽象层、 对外标准 MCP Server、按难度路由模型与成本核算、输入输出护栏（含提示注入检测）、调用链路追踪、Pydantic 结构化输出、知识图谱检索。 接进 /api/chat 要多 2–3 次模型调用，延迟与成本待产品决策
未接线 • imported	evaluation	已被运维面板引用做规则评估，但完整自动评估流程未接入对话链路

图 9-1　Agent 模块接线状态（面板实测计数）



9.5 运维面板：让每个数字知道自己是量的还是推的

llm_usage	调用次数、输入 / 输出 token、其中缓存命中 token、耗时、单价与金额；未配单价时只报 token 不报钱，并在接口里写明原因
image_usage	出图请求数、复用命中、净省张数、复用率、按场景分布、失败原因分类；标明进程计数与库内累计的差别
answer_quality	点赞 / 点踩 / 未投票分桶 + 规则失败样本原文（问题 + 命中规则）
agent_modules	wired / unwired / imported_but_unwired 计数与逐模块原因
validation	runs / issues / degraded_runs / by_stage / rag 检索错误计数 / last_error
chat_streams	active / cancelled / client_disconnected
llm_cache • long_term_memory • session_memory	语义缓存可用与开关、长期记忆条数与平均置信度、会话摘要缓存状态
degradation	日志文件可写性等降级留痕；运维指标持久化 + 阈值告警

计量是纯旁路：读计数、写台账都包在 try/except 里，计量失败绝不改变用户拿到的答复；上游请求体不因计量新增字段； 计时统一走一个入口，避免各处口径不一。

第 10 章　异常处理设计

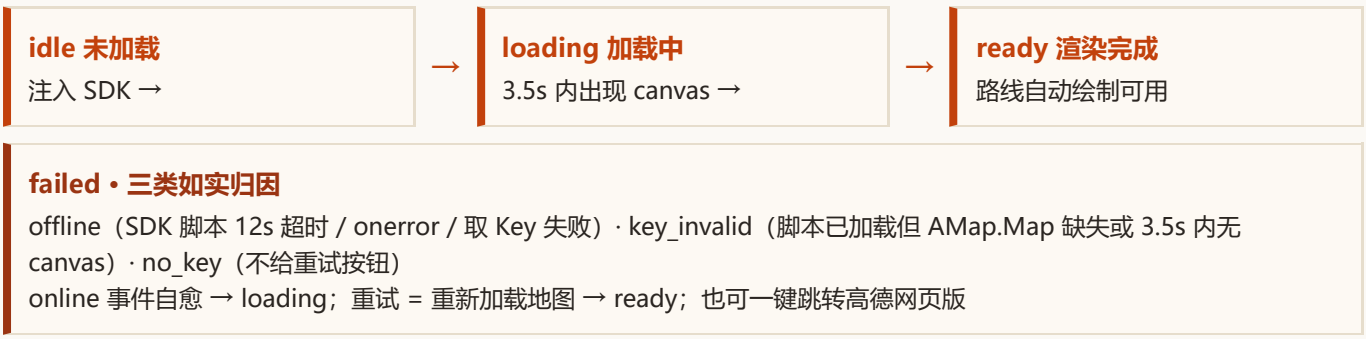
系统对五类典型异常给出明确处理策略，原则是「失败不空白」：需求不完整 → 澄清话术；信息无法确认 → 标注「暂未核实」并给替代建议； 网络异常 → 降级本地知识库；模型异常 → 返回最小可用框架；第三方资源失败 → 可归因、可重试（10.3 地图状态机）。

10.3 地图加载状态机（第三方资源不可用的如实归因）

表 10-1　异常与稳健性：工程量化约定 实测

项	参数	依据 / 行为
LLM 发送层	重试 1 次 · 退避 1.5s · 可重试码 timeout / network / busy / server	备用通道走 SMARTTOURISM_LLM_FALLBACK_BASE_URL / _KEY / _MODEL，主通道故障时改道而不是直接失败
模型调用超时	非流式 120s · 流式 180s	流式另有看门狗，超时按中断处理并保留已生成部分
生图超时对齐	生图 150s · 拉图 60s · 前端 abort 215s	修掉「上游已计费、本地先放弃」的错位（见 6.3）
美团接口	timeout 30s · 结果缓存 TTL 300s · stale 上限 24h · 容量 200 条	实测上游 11–44s；TTL 内同城同问不重复打接口；故障时回退最近一次成功数据，并在提示词里标明「这是多久前的数据、仅供参考」，绝不拿旧价假装实时价
高德 QPS 限流封装	锁 + 最小间隔 0.16s + 3 次尝试	1 次首发 + 2 次退避重试（0.25s×n），单次 timeout=8s
口令散列	PBKDF2-HMAC-SHA256 · 100,000 轮 · 16 字节随机盐	salt$hex 存储，源码与提交包不含任何明文口令
图形验证码	一次性 SVG · TTL 300s · 4 字符去混淆	取出即失效；注册与登录均校验
登录令牌 / 流会话	TOKEN_TTL_DAYS 7 · STREAM_TTL_S 900	过期令牌与孤儿流定期清理，不无界增长
热路径 DB / 日志写失败	DAO 统一护栏 @guarded()	后台留痕写失败只记日志，不吞掉已经生成好的答复；用户主动 CRUD 失败则如实报错而不是假装成功
多线程共享状态	waitress threads=8	修复三处共享状态（会话缓存、插件预订入口、语义缓存锁），避免串数据与无界内存；test_concurrency 22 项
模型空输出 / 超时	返回最小可用行程框架	提示二次确认；流式中断保留已生成部分并标「可能不完整」
关键操作	二次确认	删除会话 / 行程等不可逆动作防误触

图 10-1　地图加载状态机与三类失败归因



技术细节只在 ?debug=1 展开，用户只看「发生了什么 + 能做什么」；地图挂掉不阻断行程内容与定位。 设计原则：任何异常都给「可操作的下一步」，拒绝空白页式失败。

第 11 章　测试与效果对比

全量回归一条命令：`python run_tests.py`，逐个执行 server/、server/agent/、plugins/ 下的测试脚本并汇总通过数。 最近一次运行（2026-10-05 18:37 实测）结果为 **36 文件 • 1,716 项通过 • 0 失败。**

测试按主题分文件而不是按模块分文件，是为了让「哪一类行为退化了」在一条命令的输出里直接可读； 每个脚本以子进程执行，避免全局状态、端口与缓存互相污染。断言只打真实行为而不打调用痕迹—— 例如「新建对话之后旧会话必须还在」「比对不上就不许删」「命中缓存则不发网络请求」， 这三条如果只检查函数有没有被调用，实现改坏了照样全绿。

图 11-1　测试与清洁化自检结果（全部【实测】）

36 / 1716
回归测试文件 / 测试项，0 失败

114
美团结果缓存（TTL 命中 + stale-if-error）

112
答复反馈与质量指标

78
个人中心「只留真实链路」

76
多会话管理与用户隔离

71
生图计量与超时对齐

57
上下文管理与持久化读回

47
凭据清洁化自检（提交包 0 残留）

0 / 0
敏感信息残留 / 学校信息红线命中

认证与数据隔离断言并入 test_session_management（含「列表按 user_id 隔离」）、test_data_export 与 test_profile_center； 清洁提交包敏感信息自检与学校信息红线扫描由 prepare_submission.py 在打包时执行，两个扫描均为 0 命中。

表 11-1　回归套件构成（按主题归组，括号为通过项数） 实测

主题	测试脚本（项数）	覆盖点
对话链路	session_management(76) · stream_stop(71) · regenerate(44) · feedback_metrics(112)	多会话隔离、真停流、只撤本轮、反馈落库与回放状态
上下文与记忆	context_manager(57) · agent/memory(79)	预算装配、溢出折叠、事实锚定、摘要与长期记忆持久化
数据来源与反幻觉	rag_sources(38) · validation_degrade(42) · agent/rag_hybrid(41) · agent/guardrails(41)	出处可见、校验降级计数、混合检索、护栏
成本与计量	llm_usage(55) · prompt_cache(42) · image_cost(71) · agent/semantic_cache(45)	token 与缓存命中、生图复用净省、语义缓存

config 块来自启动期配置校验：不硬崩溃，只告警并把完整度暴露在 /api/health； 内置示例 Key 已移出源码改为指纹比对，仍在用示例 Key 时给出替换提示（见第 13 章凭据治理）。

主题	测试脚本（项数）	覆盖点
稳健性与并发	llm_retry(57) · llm_retry_live(21) · dao_guard(40) · hotpath_degrade(39) · concurrency(22) · meituan_cache(114)	退避重试与备用通道、DAO 护栏、热路径不吞答复、8 线程共享状态
Agent 能力库	agent/graph(17) · multi_agent(15) · hitl(18) · tools(21) · mcp_server(8) · structured_output(36) · tracing(45) · evaluation(44) · model_router(31) · graphrag(36) · agent_modules(46)	编排、多 Agent、HITL、工具、MCP、结构化输出、追踪、评估、路由、图谱与接线状态自检
业务与界面	profile_center(78) · portal_showcase(57) · data_export(50) · ops_log(60) · secret_hygiene(47)	只留有数据来源的栏目、门户展示、整包导出、留痕与凭据自检

附：/api/health 实测响应（GET /api/health → 200 OK，2026-10-05 18:40）


```
{"status":"ok","service":"SmartTourism","version":"v2.2.0","provider":"DeepSeek",
"plugins_loaded":7,"plugins_configured":6,"skills_loaded":["tourism-advisor",
"tourism-marketing","smart-matching"],"crowds_loaded":["family_young","gen_z",
"couple","senior","business","team_building"],"has_api_key":true,"has_amap_key":true,
"config":{"complete":true,"missing_required":[],"warnings":[]},
"environment":"development","debug":false,"timestamp":"2026-10-05T18:40:55"}
```


11.2 逐环节效果对比

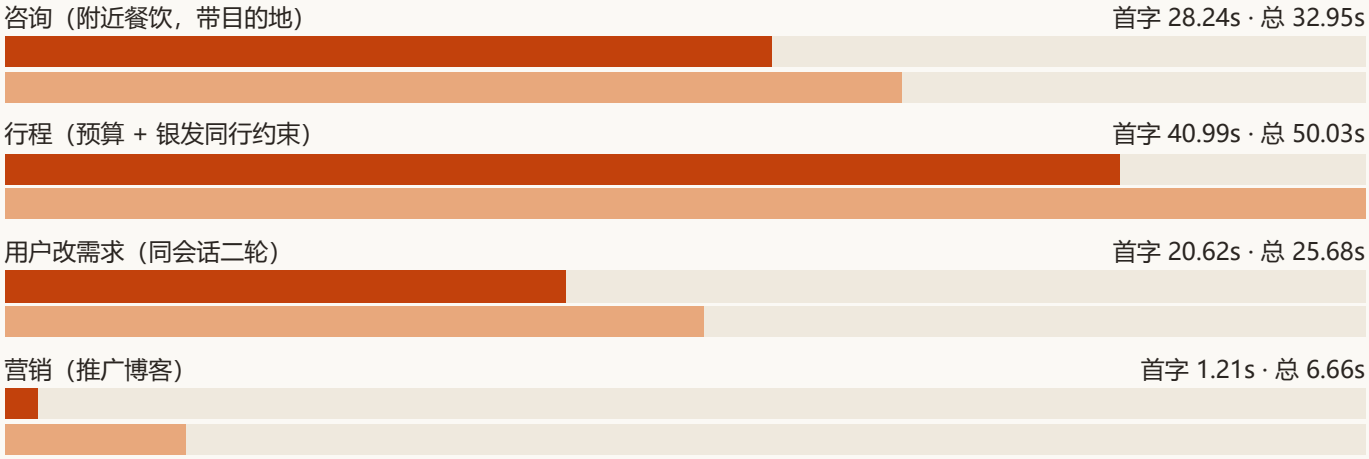
表 11-2　原方式 vs 引入 AI 后的效果对比

环节	原方式	引入 AI 后	数据性质
3 天个性化行程	人工查攻略 + 比价 + 排线约 2–4 小时/份	首次生成 30–60s（含实时天气 / 票价拉取），缓存后 10–20s；实测行程场景总耗时 50.03s、首字 40.99s	AI 耗时【实测】；人工基线为经验估计【预期】
行程适配度	固定模板，千人一面	同城市不同画像产出可复现的差异化方案	【实测】/api/plan 多次调用对比
营销文案	人工约 1–2 小时/篇 或套模板不贴文化	10–30s/篇，含平台适配 + 转化路径 + 合规检查；实测 6.66s 成文 1,227 字	生成耗时【实测】
长对话稳定性	固定截断最近 20 条，早期约束丢失	预算内贪心装入 + 溢出折叠摘要，输入 token 不再线性膨胀；摘要与事实已持久化	【实测】7 轮溢出用例（表 8-2）
环节	**原方式**	**引入 AI 后**	**数据性质**
信息可信度	人工易抄错价格 / 开放时间	价格 / 开放时间强制标注来源（美团 / 高德 / 本地知识库），知识库检索出处可见	【实测】来源徽标与出处卡片可见
文创传播	包装印死图文，无转化入口	数字名片扫码看故事，创建 → 扫码 → 查看链路 E2E 通过；配图命中指纹复用不再重复付费	链路功能【实测】；转化幅度【预期】
对话可控性	「新建对话」清空历史；答复不能停、不能改、不能评价	多会话并行、可中途停止、可重新生成与编辑重发、答复可点赞 / 点踩并进面板	【实测】上述四项合计 303 项用例通过
接口成本可控性	重复提问重复付费；重复生图重复付费	语义缓存（TTL 900s / 阈值 0.92）+ 美团结果缓存 + 生图指纹复用 + 前缀稳定吃上下文缓存命中	【实测】命中率 37.3% 为实测值，见第 14 章

诚实披露：人工耗时基线为行业经验估计而非实测基准；数字名片的商业转化提升需上线后运营数据验证，本报告不夸大披露。「303 项」= test_session_management 76 + test_stream_stop 71 + test_regenerate 44 + test_feedback_metrics 112 之和，可在 run_tests.py 输出逐条核对。

11.3 延迟实测（与第 14 章同一次测量运行）

图 11-2　四场景首字等待与总耗时（秒，实测 2026-10-03 19:10） 实测



橙 = 首字等待，浅橙 = 总耗时，按最大值 50.03s 定标。延迟含服务端前置采集（定位 / 实时数据 / 知识库检索），与用户在界面上感受到的等待一致，不是纯模型耗时。行程与咨询类首字慢是**已知体验问题**：见第 16 章「首字延迟」条目 —— 是否改为流式优先属产品决策（作者 2026-10-02 明确暂不实现），本报告不粉饰成「秒级响应」。

第 12 章　部署与运行说明

部署三步：`pip install -r requirements.txt` → 双击 `start.bat`（或 `python server/run_server.py`）→ 浏览器访问 `http://localhost:5050`。requirements.txt 共 8 项，4 核心 + 4 可选，可选项未安装自动降级不影响启动。API Key 全部在后台配置，前端零配置。

表 12-1　部署与运行要素

项	值	说明
运行环境	Python 3.8+（开发验证 3.13）	Windows / macOS / Linux 均可
安装	pip install -r requirements.txt	4 核心 + 4 可选（见表 4-3）
启动	start.bat 或 python server/run_server.py	优先 waitress 多线程 WSGI（threads 默认 8）；未装 waitress 回退 Flask 内置服务器
端口	默认 5050，SMARTTOURISM_PORT 可覆盖	启动前探测端口占用，被占时给出中文处置提示并退出，不再抛原始 traceback
大模型 Key	后台配置（/api/config · /api/providers）	DeepSeek / 智谱 / 通义 / Kimi 运行期热切换；配置目录不入提交包
生图 Key	data/ark_config.json	火山方舟 Seedream，支持场景专属 Key
插件 Key	data/plugin_config.json	高德 / 美团等；前端零配置
单价配置	SMARTTOURISM_PRICE_IN_PER_M · _OUT_PER_M · _ARK_PER_IMAGE	不设则只报 token 与张数不报钱；模型调价时改环境变量即可，不写死在代码里

项	值	说明
无 Key 行为	自动降级本地知识库兜底	可正常启动、不崩溃、不空白页
数据	SQLite（17 张表）+ 按用户命名空间 localStorage	仅存本机；/api/export/mine 一键整包导出
测试	python run_tests.py	一条命令跑完 36 个脚本并汇总通过数
运维面板	http://127.0.0.1:5050/admin	用量、命中率、降级计数、答复质量与接线状态

start.bat 修过三处：批处理语法错误、CRLF 行尾、中文路径下的工作目录切换，现双击即可起服务。 直接跑 `python server/app.py` 时启动横幅仍打印 5000（实际监听 5050），是提示文案缺陷，保留在第 16 章。

第 13 章　AI Coding 开发实践

```
附：一次真实启动输出节选（run_server.py）
[Plugin] 注册: amap_weather  [Plugin] 注册: local_knowledge
[Plugin] 注册: fliggy        [Plugin] 注册: meituan
[Plugin] 注册: amap_poi      [Plugin] 注册: amap_map
[Plugin] 注册: travel_cost
[DB] 数据库初始化完成: .../data/smarttourism.db
==================================================
智旅灵犀 SmartTourism Server
WSGI 后端 : waitress (threads=8)
监听地址 : http://0.0.0.0:5050
运维面板 : http://127.0.0.1:5050/admin    健康检查 : http://127.0.0.1:5050/api/health
```

本项目采用人机协同开发：AI 参与需求拆解、代码生成、调试排错与测试用例编写，关键交互记录与运行日志存于 data/logs 可回溯核验； **所有 AI 生成代码均经人工逐段审查后合入。**审查发现的代表性缺陷见表 13-1 ——表中把「凭据」与「讲得出但证不了」两类一并记入。

人机协同的分工判据是一句话：AI 起草，人做主。适合交给 AI 的是输入输出明确的局部实现； 不能交的是三类全局判断——依赖要不要引入（本项目选零依赖的保守近似而不是引 tiktoken）、 失败时该沉默还是该计数（选进面板）、能力清单以什么为准（以请求路径而不是 import 过）。 表 13-1 里的缺陷没有一个能被编译或接口自检发现，它们的共同点是「看起来是对的」。

表 13-1　AI Coding 人工审查：典型缺陷案例

缺陷	为何自检漏过	发现方式与教训
在 Flask 路由函数体中间插入新路由，原有路由静默失效	py_compile 编译通过；接口未报错	人工核对 @app.route 函数边界发现并修复 —— **编译通过 ≠ 路由存在**
skill_max_tokens={"plan": 8192} 为死代码	代码确实在，分支逻辑也正确	按调用点回溯：/api/plan 未传 skill_name ——「代码写了」不等于「逻辑跑到了」。现已在两处调用显式传参并回归
启动横幅端口硬编码 5000，与实际监听 5050 不一致	只是提示文案，功能正常	报告校对时发现，列入已知限制 —— **提示文案也要过人工眼**
随项目发布的示例 API Key 以字面量写在源码里	清洁化自检的正则特征没覆盖这种「裸 32 位十六进制」写法，于是「敏感信息 0 残留」是假的	人工复核凭据链路时发现。**处置：**字面量移出源码，改为只存 sha256 指纹做「是否仍在用示例 Key」的比对； 自检补上抓裸 32 位的特征并对命中值做掩码预览；新增 47 项凭据清洁化用例锁住这条线。 **残留风险如实说明见第 16 章**：历史提交与本机备份文件里仍有该字面量，正确处置是在控制台重置这把 Key

这些缺陷均非编译或接口自检发现，而是人工回溯调用链、逐段审查与报告校对时发现 —— 质量指标不以生成代码量、对话次数或 Token 消耗计， 以「理解代码、能验证、能维护」为准。

缺陷	为何自检漏过	发现方式与教训
「建了 15 个 Agent 模块」容易被讲成「上线了 15 项 Agent 能力」	模块都能 import，单测都过，但没进请求路径	把接线状态做成面板可观测的 wired / unwired 计数，未接线模块另出一条命令可复现的离线运行记录 —— **能力清单以请求路径为准，不以 import 过为准**
成本章节用「估算」写得像实测	估算口径本身合理，但读者会当结论用	改为写测量脚本打本机真实接口、逐场景采 usage，把「估算」这一章整体换成【实测】；单价也移出代码改走环境变量，避免价签过期
上下文管理模块的设计取舍	AI 给出分层记忆通用方案（引 tiktoken / 向量库）	人工据本项目约束改为零依赖的保守 token 近似 +「最近 4 轮无条件必保」—— **AI 起草、人做主**

13.2 交付物与清洁化流程

交付物	说明
完整源码	server / server/agent / dashboard / skills / plugins / knowledge
一键部署	start.bat + server/run_server.py（端口占用探测、WSGI 回退提示）
测试	run_tests.py 一条命令跑完 36 个脚本，输出 N passed / M failed
文档	README.md · CONFIG.md · design.md · 安全与异常维护指南.md · 运行成本与延迟实测.md · Agent模块离线运行记录.md

第 14 章　运行成本与延迟实测

交付物	说明
本报告	docs/智旅灵犀_作品报告.html（源稿）+ 同目录 PDF，一条命令重印：python docs/make_report.py
作品介绍 PPT	docs/智旅灵犀_作品介绍.pptx（30 页，16:9）：六章展开（定位与洞察 / 系统与主线 / 六大优势 / 规模与证据 / 运行、价值与边界 / 交付与复现），数字与本报告同口径，图表由脚本按同一份实测数据生成
清洁化自检	prepare_submission.py：排除本机产物与配置目录，跑敏感信息特征扫描 + 学校信息红线扫描，输出 0 残留 / 0 命中才打包

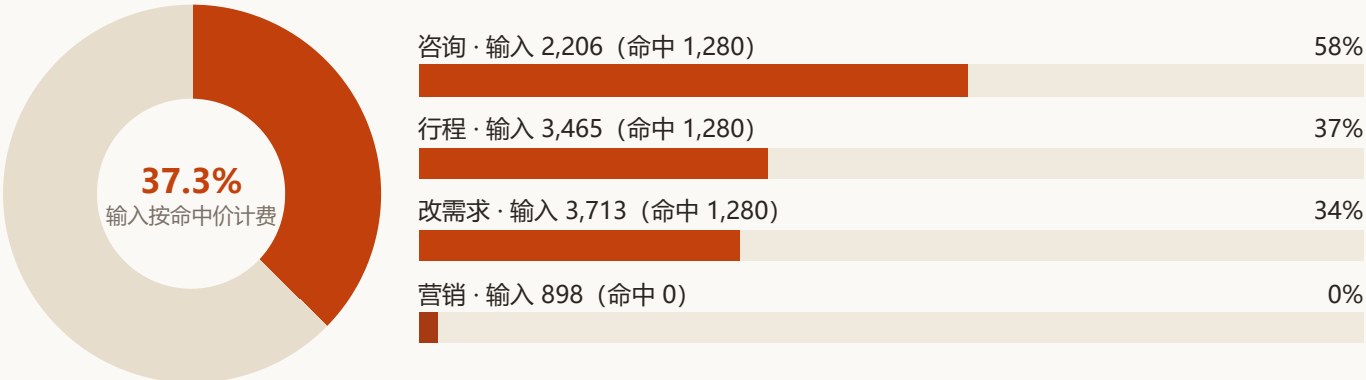
本章成本全部是【实测】，不按「tokens × 公开单价」推算 —— 由测量脚本打本机服务的真实接口，每个场景前后各读一次 `/api/admin/ops` 的 `llm_usage`，用**差值**把 token 归到具体场景， 延迟由脚本本地计时。下表没有一格是手写上去的，复现命令见 14.6。

表 14-1　逐场景实测（DeepSeek deepseek-chat • 2026-10-03 19:10 • 冷路径） 实测

场景	首字(s)	总耗时(s)	输出字数	模型调用	输入 token	其中缓存命中	输出 token
智能咨询（附近餐饮，带目的地）	28.24	32.95	580	2	2,206	1,280	772
行程规划（预算 + 银发同行约束）	40.99	50.03	1,444	2	3,465	1,280	1,556
同会话改需求（第二轮）	20.62	25.68	1,459	2	3,713	1,280	1,535
场景	首字(s)	总耗时(s)	输出字数	模型调用	输入 token	其中缓存命中	输出 token
营销博客生成	1.21	6.66	1,227	1	898	0	870
合计	—	—	**4,710**	**7**	**10,282**	**3,840 (37.3%)**	**4,733**

「模型调用 2 次」是真实账：一轮对话除正文（流式）外还有一次预生成思考（非流式）。只算正文会把成本低估一半， 这正是「按公开单价估算」最容易骗过自己的地方。7 次调用**全部**在响应里带回真实 `usage`（流式的末尾块也带）， `estimated_calls = 0` —— 本表 token 没有一个来自字符折算。

图 14-1　输入 token 与上下文缓存命中（命中数取自上游 usage 的 prompt_cache_hit_tokens）



营销场景命中为 **0**，这不是异常而是机制：上游要先见过这段前缀才会命中，**新前缀的第一次调用命中必为 0**。 营销是一段独立 prompt 且只调一次，所以它拿不到命中 —— 报告里把它如实留成 0，比抹掉这一行更有说服力。

14.2 命中从哪来：把每次都会变的值排到提示词末尾

DeepSeek 的上下文缓存按请求**前缀**命中，命中价远低于未命中价。本项目因此做了一次提示词前缀稳定化改造： 把分钟级时钟、IP 定位、Skill 正文这类每轮都变的值一律移到末尾，头部逐字不动。于是同一次提问里的两次调用共用这段头部， 同会话第二轮又共用上一轮的全部内容 —— 命中 token 随轮次上升。这不是推断：改造前后各跑一遍脚本， `prompt_cache_hit_tokens` 从 0 变成非 0，且该数值同时进了运维面板。

14.3 只报 token，不报钱：单价走环境变量

本次测量**未配置单价**，因此只报 token 不报金额 —— 接口返回里写着「未配置单价...所以只报 token 不报钱」， `llm_usage.cost` 为空。这是刻意的设计：模型厂商在 2026 年有过调价， 任何写死在文档里的价签都会过期，所以单价只留方法、不留数字，也不写进代码。

14.4 三处省钱机制与它们的证据性质

```
set SMARTTOURISM_PRICE_IN_PER_M=<输入价，元/百万 token>
set SMARTTOURISM_PRICE_OUT_PER_M=<输出价，元/百万 token>
set SMARTTOURISM_ARK_PER_IMAGE=<Seedream 单价，元/张>
python server\measure_llm_cost.py    # 按当时的官方价格页填写，金额即自动出现
```

表 14-2　成本相关的机制、参数与证据性质

机制	参数	证据性质
上下文（前缀）缓存	由上游计费侧命中，本项目只负责把前缀写稳	【实测】命中 token 与命中率均来自上游 usage，面板可见
语义缓存	TTL 900s · 相似度阈值 0.92 · 命中不再发起网络调用	【实测】装配与阈值有测试覆盖；本表量的是**冷路径**（各场景问法都不同），重复问题的实际成本低于本表
生图指纹复用	参数 sha256 指纹 + `ark_image_cache` 表	【实测】同指纹不重复出图、不重复计费（Seedream 按张计费，复用一次就少付一张）
本地部署	无服务器租金，SQLite + 本机文件	【实测】不填 Key 时全链路降级为本地知识库兜底，模型调用成本为 0

14.5 长对话让成本与延迟可预期

上下文管理给输入 token 上了硬上限（预算 24,000、滚动摘要自身 ≤300 字），溢出专项实测中 `est_input_tokens` 稳定压在 4.5k–7.8k 区间（表 8-2）。 这意味着**第 N 轮请求不会因为历史变长而线性涨价**，费用与延迟因此可预期 —— 这是第 8 章的工程能力在第 14 章的经济后果，两章是同一件事的两面。

14.6 复现命令

```
# 1) 起服务
start.bat    # 或 python server\run_server.py（监听 127.0.0.1:5050）

# 2) 逐场景实测 token 与延迟（差值归场景，全程读真实接口）
python server\measure_llm_cost.py

# 3) 实时累计值（模型用量 / 缓存命中 / 生图张数与复用率 / 答复质量）
curl http://127.0.0.1:5050/api/admin/ops    或打开 /admin 面板

# 4) 本表出处文件
运行成本与延迟实测.md（脚本生成，生成时间 2026-10-03 19:10:40）
```

第 15 章　商业价值与社会价值

诚实边界：①延迟含服务端前置采集（定位 / 实时数据 / 知识库检索），与用户在界面上感受到的等待一致，**不是纯模型耗时**；②本表单次进程累计 11 次调用，样本为 4 个场景 7 次调用，不是大样本统计，代表「这一遍跑出来的量」；③人工耗时基线（排行程 2–4 小时、写文案 1–2 小时）是行业经验估计，**本项目没有做过对照实验**，因此不给「省了多少钱 / 转化提升多少」这类收益数字 —— 要引用收益请先设计对照测量，或明确标注为假设。

价值主张由三点支撑：**画像驱动提效、印码即媒介、按量可预期成本。** 每项主张对应的机制与证据性质逐条列于表 15-1 —— 实测与预期分列，转化率类主张一律标【预期】，不冒充结论。

商业价值

服务效率：小时级 → 秒级
获客成本：素材量产 + 实物印码
客源转化：种草到下单路径变短
成本可预期：上下文预算硬上限 + 缓存命中

社会价值

文化传播：地方符号可扫码故事
适老无障碍：松弛慢游 + 替代路线
公共服务：无网 / 无 Key 拒绝空白页
数据主权：仅存本机可一键导出

表 15-1　主张、机制与证据性质

价值主张	机制	证据性质
服务效率提升	行程 / 文案产出从小时级降至十至五十秒级，人力释放到服务与创意环节	AI 侧耗时【实测】（表 14-1：行程 50.03s、营销 6.66s）；人工基线为行业经验【预期】
获客成本降低	营销素材零门槛量产 + 数字名片让实物包装自带转化入口	链路功能【实测】（创建→扫码→查看）；转化幅度【预期】
客源转化改善	行程内嵌消费触点与美团购票直达深链，种草到下单路径变短	触点与深链【实测】；转化【预期】

价值主张	机制	证据性质
成本可预期	本地部署 + 按量调用 + 上下文预算硬上限（24,000 tokens）+ 前缀缓存命中 + 生图指纹复用	token 与命中率【实测】；金额因未配单价留空，口径公开可复核
文化传播	非遗 / 博物馆 / 地方符号转译为可消费文创与可扫码故事，含 IP 合规检查	功能【实测】
适老与无障碍	松弛慢游 / 体力节奏参数，为银发与体力受限人群降强度并给替代路线	功能【实测】
公共旅游服务	无 Key、无网络时本地知识库兜底与澄清提示，拒绝空白页式失败	降级行为【实测】
数据主权	全部数据仅存本机，SQLite + 按用户命名空间 localStorage，一键整包导出	导出接口【实测】

图 15-1　人工耗时 vs 本系统耗时（对数刻度，柱长仅示意量级差异）



柱长按 $\log_{10}$(秒) 缩放，仅示意量级差异，不代表线性比例。人工基线是行业经验估计【预期】而非实测基准 —— **本项目没有做过人工对照实验**，因此不给「效率提升 N%」这类百分比结论；要引用收益请先设计对照测量，或明确标注为假设。

15.2 与运维面板的对应关系

价值不是形容词，面板上每一格都有出处：`/admin` 读 `/api/admin/ops`， 展示模型用量与缓存命中、生图张数与复用率、上下文压缩计数、答复质量（点赞 / 点踩分桶 + 失败样本）、 对话流取消与断连计数、以及 Agent 模块「已接线 / 未接线」。成本与效率的主张因此可以在答辩现场当场复现， 而不是停留在 PPT 上。

第 16 章　已知限制与未来展望

限制逐条诚实披露，并区分三种状态：已修复 改动已合入且回归通过、未修复 已定位仍在、保持 属外部条件或产品决策，如实说明不掩盖。

把限制写进正文而不是删掉，是成本更低的选择：被追问一条已写明的限制，代价是一句话；被追问一条没写的， 代价是整份报告的可信度。所以每条限制都带状态与出处，已修复的附回归项，未修复的写明定位到的文件与行号， 属外部条件的（账户欠费、第三方城市覆盖）不伪装成代码问题。

16.2 未来展望

表 16-1　已知限制、影响与处置状态

限制	影响	状态	证据 / 处置
plan 输出上限 8192 的提升分支是死代码	超长行程尾部（第九模块起）有截断风险	已修复	根因是调用点未传 `skill_name`；现已在 `app.py:3422 / 3425` 显式传 `"plan"`，营销与文创仍按 4096
上下文滚动摘要只在内存里，重启即失忆	重启后首轮可能多一次摘要调用，早期约束丢失	已修复	摘要落库 `sessions.history_summary`，启动期 `restore_summary` 预热（`app.py:952`），并有 `PUT /api/sessions/<id>/summary`
启动横幅端口硬编码 5000，实际监听 5050	提示文案误导；**答复内的地图链接同样写死 localhost:5000**，点了打不开	未修复	已定位 `app.py:7669` 与 `app.py:790`；当前只更新文档，未顺手改代码，列入下一步修复
违规词规则会把正常表述判成违规	面板 `no_banned_terms` 通过率因此偏低，不能作为质量结论	未修复	词表含「第一」「最佳」，实现是朴素子串匹配（`evaluation.py:75-79 / 198`），于是「第一天上午」也命中。**选择保留误报、不调松阈值凑好看的通过率**，失败样本原样进面板
多人偏好平衡靠提示词规则与固定输出模块承接	同行成员的需求冲突没有求解器保证最优，只保证「逐人被写明」	保持	规则要求写明每人被满足在哪里、共同满意点在哪里（输出模块五）；本项目**未实现独立的平衡算法**，界面与报告均不宣称有
限制	**影响**	**状态**	**证据 / 处置**
火山方舟账户欠费期间生图不可用	海报 / 灵感配图返回失败并回退占位	账号状态	已可归因：检测到 `AccountOverdueError` 即返回「请到控制台充值后重试」（`app.py:7576 / 7594`），不当代码 bug 排；充值后恢复
11 个 Agent 模块建好但未进请求路径	不能对外宣称在线提供这些 Agent 能力	产品决策	接进 `/api/chat` 要多 2–3 次模型调用，延迟与成本待决策；已做成 `python server/agent_offline_demo.py` → 11 ok / 0 failed 的可复现记录
随项目发布的默认示例 Key	历史提交里仍可检出该字面量	部分处置	字面量已移出当前源码，改为只存 sha256 指纹做「是否仍在用示例 Key」的比对，自检补上裸 32 位十六进制特征 + 47 项清洁化用例；**残留：25 个历史提交与 dashboard/_backup/*.bak 里仍在。正确处置是在控制台重置这把 Key**，改文档不能消除已入库的值

限制	影响	状态	证据 / 处置
实时票价与天气依赖第三方 token	未配置或城市无覆盖时无实时数据	保持	自动降级并标注来源，查无可靠来源标「暂未核实」，绝不编造；美团实测 11–44s，故有 TTL 300s 缓存 + stale-if-error（回退旧数据必须标明数据年龄）
数字名片商业转化幅度未验证	只有链路可用性证据	保持	上线后以 `operation_logs` 做转化漏斗验证；在此之前该主张只写【预期】
效率对比缺人工基线实测	量级对照可讲，百分比不可讲	保持	需设计对照实验；本报告一律标【经验估计】并说明缺口
限制	影响	状态	证据 / 处置
灵感配图首屏约 16s（2026-09 记录）	首次生成期间显示占位	保持	保存名片已异步预热；同指纹复用不重复出图；极端并发仍可能等待
黑暗模式为测试功能	地图底图与海报画布未适配	保持	界面带测试角标明示测试状态，不谎称已完成

- **按优先级修掉文案层缺陷**：启动横幅与答复内地图链接的端口写死（`app.py:7669 / 790`），改为读运行时监听值；同时把违规词规则从子串匹配改为带上下文的判定，让面板通过率变成可用的质量信号。
- **凭证治理收口**：在控制台重置示例 Key（唯一能真正消除历史提交残留的动作），并把清洁化自检扩展为扫描 `git log -p`，让「0 残留」这句话覆盖历史而非只覆盖工作区。
- **按需接入 Agent 编排**：以「首字延迟与单次成本增幅」为闸门，逐模块决定接线顺序（优先 guardrails 与 evaluation，其次 structured_output），接线状态变化同步进面板计数，能力清单始终以请求路径为准。
- **接入更多 OTA 交易闭环**，打通从推荐到下单的全链路；扩展多语言服务覆盖入境游客。
- **用 operation_logs 做转化漏斗**，把「预期」变成「实测」；并据此持续调推荐与生成策略。
- **记忆升级为可持久化分层结构**（长期事实库 + 会话摘要），把事实锚定扩展到跨会话。
- **建立人工对照基线**，做一次真实的小样本效率测量，让效率主张从「量级」升级到「数字」。

结语

综上，智旅灵犀以 4 个核心依赖的轻量架构，把「画像驱动的行程规划」与「印码即媒介的数字名片」两条主线做深做透； 以四级数据来源与三道反幻觉闸口保证结果可信，以全链路降级保证系统可用，以运维面板把成本、命中率与未接线模块如实摊开。 本报告的全部数字都出自源码统计、真实接口与自动化测试，**可核验、可复现，也可被推翻** —— 凡做不到或未验证的，宁可留一条限制，也不写进结论。

这个项目更想被看见的不是功能数量，而是它处理「说得出」与「证得了」之间距离的方式：能测的都测并留下命令， 测不了的标明性质并留下缺口，做了一半的如实分成已接线与未接线。下一步的工作因此不是再加几个模块， 而是把第 16 章里那几条「未修复」与「保持」逐条收掉。

全报告关键数字回顾（均可由文末命令复现）

85 / 91
唯一 REST 路径 / 路由声明 源码统计

4 + 4
核心依赖 / 可选依赖（requirements 共 8 项）

1716
回归测试项 · 36 个脚本 · 0 失败

7 / 3 / 6
数据插件 / OpenClaw 式 Skill / 客群画像

37.3%
长对话输入 token 缓存命中（3,840 / 10,282）

0
字符折算 token 调用 —— 7 次全部拿到真实 usage

4.5k–7.8k
7 轮溢出实测的输入 token 有界区间

11 ok / 0 failed
未接线 Agent 模块的离线运行记录

数据出处与复现一览

接口与代码规模	对 server/ 全部 `@app.route` 与 `.py` 逐条统计（表 4-4 与 4.5 节）
插件 / Skill / 画像	`curl http://127.0.0.1:5050/api/health`
测试	`python run_tests.py` → 36 文件 / 1716 passed / 0 failed
成本与延迟	`python server/measure_llm_cost.py` （表 14-1）
接口与代码规模	对 server/ 全部 `@app.route` 与 `.py` 逐条统计（表 4-4 与 4.5 节）
上下文溢出	临时实例设 `CTX_BUDGET=2600` · `CTX_RECENT_ROUNDS=2` 连发 7 轮，读 /api/chat 的 context 元数据（表 8-2）； 长期回归走 `python server/test_context_manager.py`
Agent 模块	`python server/agent_offline_demo.py` + `/api/admin/ops` 的 agent_modules 计数
清洁化自检	`python prepare_submission.py` （敏感信息 0 残留 / 学校信息红线 0 命中；历史提交残留见第 16 章）