灵

智旅灵犀 · 文旅全场景智能辅助系统

作 品 报 告

游客画像驱动 × 消费转化设计 × 文创产品赋能

基于 AI Coding 的轻量化智能 Skill 协同实践

Flask + waitress 后端 · 原生 JS 零框架前端 · 国产大模型运行期热切换 · 火山方舟 Seedream 生图

85	7 + 3	1716	37.3%
唯一 REST 路径	数据插件 / OpenClaw 式 Skill	回归测试项 · 0 失败	长对话输入 token 缓存命中

软件版本 v2.2.0 | 参赛赛道：文旅智能辅助场景（AI Coding / OpenClaw 引擎规范） | 2026 年 10 月
全部数据截至提交 `d89ae53`，全量回归与离线运行记录实测于 2026-10-05， 全部数字可由 `python run_tests.py` 与源码统计复现

目　录

1 应用背景与痛点 3
1.1 需求边界 3
1.2 三条设计约束 4
1.3 这份报告怎么读 4
2 场景描述与目标用户 5
2.1 三类目标用户 5
2.2 场景一 从想法到出发 5
2.3 场景二 素材变名片 5
2.4 七类同行关系 5
2.5 策略库里的原文 6
2.6 场景三 长对话可控性 6
2.7 场景四 从热点到可售内容 7
3 技术创新点 8
3.1 Agent 编排与能力分层 8
3.2 三个 Skill 能力包 8
3.3 长对话上下文 9
3.4 数据来源分层 9
3.5 三道闸口与降级不静默 10
3.6 检索出处可见 10
3.7 成本可控 10
3.8 模型层热切换与容错 11
3.9 AI Coding 开发实践 11
4 实用性与落地验证 12
4.1 功能总览：六个界面入口 12
4.2 规划：人群 · 约束 · 产出 13
4.3 对话：十项答复控制 14
4.4 营销：六类内容与数字名片 15
4.5 首页 · 社区 · 我的 16
4.6 工程规模与质量 17
4.7 部署与运行 17
4.8 测试怎么组织 18
4.9 量级对照 18
4.10 数据主权与可交付性 19
4.11 实用性判断 19
5 已知边界与复现方式 20
5.1 已知限制 20
5.2 数据口径约定 20
5.3 复现命令 21
5.4 下一步 21
5.5 结语 21

智旅灵犀 · 文旅全场景智能辅助系统

作品报告 | 面向游客、文旅商户与景区运营方的多 Agent 智能辅助系统

软件版本 v2.2.0 | 参赛赛道：文旅智能辅助场景（AI Coding / OpenClaw 应用）
技术栈：Flask + LangGraph + SQLite + 原生前端 | 运行形态：本机一键启动，数据仅存本机，不依赖云服务

1 应用背景与痛点

文旅消费长期存在三处结构性错配。**游客侧**：攻略、票价、开放时间、天气、路线分散在多个入口，一条行程要自己反复核对拼接， 而通用大模型给出的价格与营业时间常常已经过期，越具体越容易错。**商户侧**：中小景区、民宿与文创店主既不会写文案也请不起设计， 一条素材以小时计，做完就停在一段文字上，没有可落地的转化入口。**运营侧**：把 AI 接进真实业务时，最贵的不是模型调用费， 而是「错了没人知道」——幻觉无法拦截、成本无法核算、长对话无法收敛。

本项目针对这三处错配做成一套可直接部署的完整系统：以**客群画像驱动**的行程规划与营销素材生成作为两条主链路； 以**数据来源分层 + 三道闸口**守住真实性；以**上下文预算与真实 token 计量**守住成本； 并把产出物本身（带二维码的数字名片）做成获客入口，让「生成」与「转化」在同一条链路上闭合。

2 条
主链路：个性化行程规划 / 营销素材与数字名片

4 层
数据来源分级接入，本地库仅作最后兜底

3 道
闸口反幻觉，且降级不静默、可回溯

1716 项
自动化断言全绿，0 失败（实测）

1.1 需求边界：做什么、不做什么

做：行程规划与动态调整、行程内消费触点、营销文案与文创数字名片、长对话稳定运行、运行成本与数据出处可核。 **不做**：不接支付与真实下单（只提供官方购票深链跳转到平台），不做需要个人身份的功能， 也不承诺转化率——**未做人工对照实验**，故不给「效率提升 N%」这类结论，人工耗时基线只作经验估计并标注。

1.2 三条设计约束：为什么不是「接一个大模型 API」

文旅场景里，「接个大模型」和「做成一个能用的系统」之间隔着三件事，本项目的架构选择全部围绕这三件事展开。 **第一是真实性**：通用模型给出的票价与开放时间常常已经过期，而且越具体越像真的。本系统不把这件事交给一句提示词， 而是把它做成系统属性——数据来源分四层按优先级接入、每层不可用都有明确退路、每张结果卡片都带出处徽标（见 3.4、3.5）。

第二是成本：对话越长历史越长，输入 token 线性膨胀，费用与延迟都不可预期。本系统给输入上硬预算 （`CTX_BUDGET = 24000`），把每轮都变的值排到提示词末尾以吃上游缓存命中， 并按真实 usage 逐场景计量而不是按公开单价推算（见 3.3、3.7）。

第三是可用性：产出必须落到一个可执行的对象上，而不是一段还要人再加工的文字。 行程要能落到可导航的路线与可点开的购票深链，素材要能落到可复制的正文与可印刷的二维码名片， 数据要能落到一键导出的整包文件——「印码即媒介」就是这个意思：产出物本身就是入口（见 2.3、4.1）。

表 1-1　三处错配 · 系统对策 · 展开位置

错配在哪	系统对策	展开在哪
游客侧：入口分散，模型给的票价与营业时间常已过期	四层数据来源 + 三道闸口 + 出处徽标	2.2 / 3.4 / 3.5
商户侧：素材做完停在一段文字，没有转化入口	五类成文规格 + 数字名片印码	2.3 / 2.7 / 4.1
运营侧：幻觉拦不住、成本算不清、长对话收不拢	真实 token 计量 + 输入预算 + 会话可控	2.6 / 3.3 / 3.7

1.3 这份报告怎么读

全文按「应用背景 → 场景描述 → 技术创新 → 实用性与落地 → 已知边界」推进，对应评委关注的四项： 第 1 章讲为什么值得做，第 2 章讲做出来是什么样子，第 3 章讲技术上做了什么别人没做的， 第 4 章讲它跑得起来并且量得清，第 5 章把没做到的写清楚。所有数字都带性质标签： 实测 由脚本或面板读自真实运行系统并附复现命令， 经验估计 口径公开可复核， 预期 尚未验证的目标。 三类不混用、不互相冒充；完整实现细节见技术附件《作品报告》（全 34 页），按章展开。

真实性
四层数据来源 + 三道闸口 + 出处徽标，查不到就标注，绝不编造

可预期
输入预算硬上限 + 真实 token 计量 + 缓存命中与生图复用

能落地
能导航的路线 · 能印刷的名片 · 能导出的整包数据

2　场景描述与目标用户

2.1 三类目标用户

自由行游客
要一条能直接出发的行程：几点到、怎么去、门票多少、下雨怎么改，而不是又一篇攻略

文旅商户
景区、民宿、餐饮、文创店主：要能直接发的文案与带扫码入口的成品素材

运营与推广方
需要按客群批量出内容、看真实热度、算得清每次调用花了多少

2.2 场景一　一次自由行，从想法到出发

① 说需求
缺要素先被追问，不靠猜
→
② 选客群
七类同行关系定节奏
→
③ 出行程
含时段、路线、票价与深链
→
④ 接着改
「第二天太赶」就地重排
→
⑤ 带走
导出、分享、存为我的攻略

用户只说「出去玩三天」时，系统不补全假设，而是返回澄清问题，把目的地、天数、预算、人群补齐后才开始生成。 生成过程分阶段可见：思考 → 检索 → 规划 → 审校。产出里的地点带开放时间、票价、地址与来源标注， 实时数据可用时价格标「来源：美团（实时）」并挂购票直达链接，取不到时明写「暂未获取到实时数据」而不编数， 并给出体力节奏与雨天替代路线。行程可在同一会话里连续修改，不必重头再问。一次完整行程生成总耗时 50.03s、输出 1,444 字（含实时天气与票价采集，非纯模型耗时） 实测 。

2.3 场景二　一条素材，变成一张能扫码的名片

商户选一个景点或文创产品，一次成文：正文文案与平台适配版本一起出，广告法极限词等合规口径写进成文规格， 数字类内容只走卡片式呈现，文创产品则单独出「数字名片」形态。单篇文案生成 6.66s、首字 1.21s、成文 1,227 字 实测 。 文案可一键转成带二维码的数字名片，印刷到包装、桌牌或展板上，扫码即达这条内容页—— 把转化路径从「回去搜一下」缩短成「当场扫一下」，这是本项目「印码即媒介」的落点。

2.4 七类同行关系与差异化产出

规划界面上的「同行关系」有七个选项：情侣/伴侣、亲子家庭、朋友/闺蜜、银发同行、商务差旅、团建团队、独自旅行， 归一化后落到七套成文客群策略（详见 4.2）。换不同客群即产出**可复现的差异化方案**——每日景点数、动线密度、 住宿品类、餐饮档次与消费点清单都会变，不是同一模板换措辞。这一条通过多次调用 `/api/plan` 对比验证 实测 。

2.5 客群差异不是换措辞：策略库里的原文

差异化不靠提示词里加一句「请考虑老年人」，而是有两处可查的口径。`tourism-advisor` 的 `CROWD_STRATEGIES` 为规划侧七类客群各给出景点、住宿、餐饮、节奏与消费点五项策略， 直接决定动线密度与住宿品类； `smart-matching` 另有六类客群画像库 （ `/api/health` 实测返回 `crowds_loaded: 6` ），服务匹配与营销侧。 两段原文可以直接对比：**银发康养**的节奏是「慢节奏，每天 1-2 个景点，步行为主」，住宿要求「电梯、低楼层、安静、医疗配套、无障碍」， 餐饮是「清淡、软食、养生餐、正餐准时」；**学生穷游**的节奏是「紧凑高效，公共交通，每天 3-4 个景点」， 住宿是「青旅、民宿床位、交通便利、安全」，餐饮是「本地小吃、性价比优先、分量大」。 同一座城市换到这两类客群下，规则骨架层就落到不同的每日景点数与不同的住宿品类上——差异发生在行程结构上，而不是文案措辞上。

消费触点同样在策略库里成表：亲子家庭挂「亲子套票 / 儿童体验项目 / 主题餐厅」，情侣挂「情侣套餐 / 夜游演艺 / 摄影服务」， 银发康养挂「康养体验 / 文化讲解 / 适老化文创」。行程因此天然带着「到哪里可以花钱」的入口，而不只是一张观光清单， 这是把规划与转化放进同一条链路的做法。

2.6 场景三　一条长对话里的可控性

规划与营销之外，第三个场景是「用得久」。真实用户不会一问一答就走，而多数演示在第三轮就开始丢前面的约束。 本系统把对话控制做成四项能力：**多会话并行**（会话列表按用户隔离，新建对话不再删除历史）、 **停止生成**（真停上游流并释放线程，半截答复按「可能不完整」落库，不冒充完整答复）、 **重新生成 / 编辑重发**（撤回只撤「这一轮」，比对不上就一律不删，防误删历史）、 **点赞点踩**（反馈落库，回放时投票状态不丢，规则指标进运维面板）。

这四条按主题分文件写成回归： `test_session_management` 76 项、 `test_stream_stop` 71 项、 `test_regenerate` 44 项、 `test_feedback_metrics` 112 项，合计 303 项 实测 。 另有上下文占用进度条与到 75% 触发线自动压缩（ `test_context_manager` 57 项）， 让「聊得长」在界面上是看得见的状态，而不是等回答变慢才发现。

76 项	71 项	44 项	112 项
多会话：列表按用户隔离，新建对话不删历史	停止生成：上游流真停、线程释放、半截标「可能不完整」	重新生成 / 编辑重发：只撤这一轮，比对不上不删	点赞点踩：反馈落库，回放时投票状态不丢

这四条看着不像「AI 亮点」，但没有它们，长对话产品的证据就积累不起来：反馈不落库就没有答复质量指标， 停止不真停就说不清上游流占了多少线程，会话不隔离就没法把成本按场景归账，摘要不落库就会在重启后丢掉已确认的预算与人群。 本项目把这四件事都做成有断言的功能，而不是留给运气，也不写进「后续规划」。

2.7 场景四　运营与推广方：从热点到可售内容

前三个场景的共同点是「一次要一份」，运营方的需求相反：**要批量、要按客群出、要算得清。** 这条链路从真实热点开始——抖音实时热点经接口进入灵感库，卡片带的是接口返回的真实热度值而不是编出来的数字， 12 小时滚动热点池落盘持久化，重启不丢；热点再经二次验证才出卡，宁缺不假。 拿到选题后一次成文，产出物按用途分五类规格，每类有自己的结构、篇幅与语感要求：

表 2-1　五类文案规格（取自 `app.py` 的 `type_specs`，逐条对应真实提示词约束；表单里的第六类「文创产品概念」另走 `/api/creative`，不在本表）

内容类型	篇幅口径	结构要求
社交媒体种草	全文 ≤120 字	噱头主标题 ≤14 字 · 一句传播语 ≤20 字 · 三个亮点各 ≤16 字 · 行动号召 ≤20 字 · 3~5 个话题标签
公众号推文	600~900 字	标题 ≤20 字 · 导语 2~3 句 · 三个小节各 80~150 字（是什么 / 好在哪 / 怎么玩）· 结尾给行动入口
短视频分镜脚本	15~30 秒 · 4~6 镜	前 3 秒钩子 · 每镜一行「镜N | 时长 | 画面 | 口播 | 字幕花字」· 末镜 CTA
海报文案	全文 ≤100 字	主标题 ≤12 字 · 副标题 ≤20 字 · slogan ≤16 字 · 卖点三条各 ≤10 字 · 行动号召 ≤15 字 · 视觉建议一句
活动策划案	400~600 字	活动名称 ≤16 字 · 主题 slogan ≤20 字 · 时间地点一句 · 环节流程 3~5 个环节 · 活动亮点 2~3 条 · 宣传与转化

五类规格写在提示词里，因此「短」是真的短：种草文案超过 120 字、海报超过 100 字就不算合格产出， 这类约束能被断言，也就能被复现。文创产品另出「数字名片」形态（带二维码，扫码直达该条内容页）， 让线下包装、桌牌与展板成为可统计的入口；每次调用的 token 与耗时进运维面板， 批量出内容时「这一批花了多少」是可以查的数，而不是感觉 实测 。

① 采热点
抖音实时接口 · 12 小时滚动池

→

② 二次验证
验真才出卡 · 带真实热度值

→

③ 成五类文
规格写进提示词 · 附合规检查

→

④ 出名片
文创产品 · 二维码印码

→

⑤ 可统计
扫码进面板 · 调用量算得清

这条链路与游客侧共用同一套闸口：营销生成同样先过输入闸口（缺参先澄清），输出同样拦绝对化用语与无来源的价格表述， 所以「短」和「真」是同一次约束的两面。表 2-1 的每一格都取自 `app.py` 里 `type_specs` 的真实提示词约束，不是事后排版规则——能被断言的篇幅才算规格，否则只是偏好。

3 技术创新点

本章按创新层次排列，而不是按实现顺序：先讲智能体与 Skill 层（3.1 ~ 3.3），它决定这套系统「能被追问什么、能交付成什么形态」； 再讲支撑它的工程层（3.4 ~ 3.9），它决定说出口的价格、出处与成本能不能被核得上。

3.1 Agent 编排与能力分层：多角色图 + 标准 MCP + Skill 能力包

对话用 LangGraph `StateGraph` 编排，规划 / 执行 / 审校多角色分工，工具走标准 Function-Calling， 并对外提供**标准 MCP Server**，同一批能力既能被自己的界面调用，也能被外部 Agent 按标准协议调用。 其上挂了链路追踪、答复质量评估、Guardrails 与提示注入防护、语义缓存、模型路由与 GraphRAG。 **接线状态如实可查**：面板区分 `wired_active` / `wired_idle` / `not_wired` 三态，未接线模块绝不进请求路径，另有离线运行记录（11 ok / 0 failed） 实测 。

① 意图闸口 必填三要素缺失即返回澄清话术，先于任何模型调用发生

↓ 需求齐备才往下

② 编排层 · LangGraph StateGraph 规划 / 执行 / 审校多角色分工，状态与中断点可回放

↓ 按步骤取用工具

③ 工具层 · Function-Calling + MCP Server 7 个插件在服务端注册，对外按标准协议暴露

↓ 专业知识由能力包供给

④ 能力包层 · 3 个 Skill 把文旅专业知识写成可版本化、可复用的文件，注入提示词生效

3.2 三个 Skill：把文旅专业知识做成可调用的能力包

tourism-advisor

咨询与规划：景点 / 住宿 / 餐饮 / 节奏 / 消费点五项策略成表，行程按画像落结构而不是换措辞

tourism-marketing

内容与文创：五类成文规格、合规口径与数字名片形态写进能力包，出稿即平台可发版本

smart-matching

客源匹配：六类客群画像与「需求→产品→转化策略」流水线，实测加载 6 类画像

三个 Skill 按 `SKILL.md` 规范组织在 `skills/` 目录，与插件、MCP 工具是三层不同的东西： 插件管取数，工具管调用，Skill 管「这一行该怎么做才专业」。复现：起服务后 `curl http://127.0.0.1:5050/api/health` 返回插件 7 / Skill 3 / 客群 6 实测 。

3.3 长对话上下文：把 token 从「线性膨胀」变成「预算内恒定」

旧做法固定取最近 20 条历史，长对话必然带来上下文膨胀、早期硬约束丢失与漂移。本系统给输入 token 上硬预算：`CTX_BUDGET = 24000`，最近 4 轮无条件必保（宁可超预算也不断裂），更旧轮次贪心装入， 装不下则折叠进滚动摘要（压成 ≤150 字，硬上限 300 字）；摘要与已确认事实（目的地 / 天数 / 预算 / 人群）落库， **服务重启不会「首轮失忆」**。占用到 75% 自动压缩并显示进度条。零第三方依赖：不引入分词器与向量库， CJK 每字≈1、其余 len/4 保守近似，宁可高估不超发。

24,000	最近 4 轮	≤150 字	75% 水位
输入 token 硬预算上限，超出即压缩而不是无限带历史	无条件必保，早期硬约束不会在第 N 轮被挤掉	更旧轮次折叠进滚动摘要，摘要与事实落库不丢	自动压缩并在界面显示进度条，聊得多长看得见

3.4 数据来源分层：把「可信度」做成系统属性，而不是一句提示词

① 美团实时数据 门票价格、商户评分、dpurl.cn 购票深链——真实、可下单

↓ 不可用 / 超时 / 无结果

② 高德 Web 服务 POI 地址与电话、图片、天气、地图与路线规划

↓ 无覆盖

③ 抖音实时热点 经接口进入灵感库与门户展示，卡片带真实热度值

↓ 全部不可用

④ 本地知识库（最后兜底） 仅在前述均不可用、且库内确有该城市真实数据时生效

每张结果卡片都带 `source` 与 `source_detail` 徽标， 标明数据来自哪个接口、哪次查询，可展开核验；图片按「美团实拍 → 高德 POI 图」优先级取用，两源皆无时置 `image_missing` 显示「暂无图片」占位，价格取不到时标注「暂未核实」并给替代建议。

全链路绝不编造图片与价格，且每次调用均留痕（`data/logs` + `operation_logs`）可回溯——分层不是为了让数据好看，是为了让每一格都能被追问到出处。

分层顺序是取舍不是偏好：本地库最容易做也最好看，但把「库里有」当成「真实」就会把过期数据写成结论， 因此它只作最后兜底，且只在库内确有该城市数据时生效。

3.5 三道闸口 + 「降级不静默」

- **第一道 · 输入闸口**：必填三要素缺失即返回澄清话术，先于任何生成发生。
- **第二道 · 数据闸口**：价格 / 图片 / 开放时间只认实时接口与库内真实数据，缺失走占位与「暂未核实」。
- **第三道 · 输出闸口**：模型输出经 `validation` 校验（绝对化用语、无来源价格、编造图片链接），问题以 SSE 事件如实下发给前端，而不是悄悄改掉。

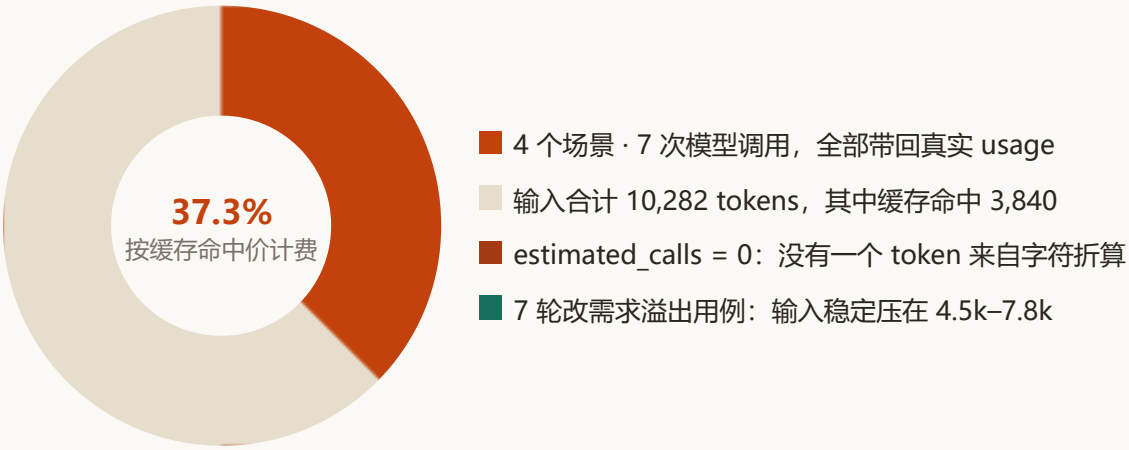
校验环节本身也可能出错，因此它按环节兜住，把 `runs / issues / degraded_runs / by_stage / last_error` 聚合进面板——能看到「哪一环掉过几次」，而不是把一次降级吞成正常通过。回归 `test_validation_degrade.py` 42 项 实测 。

3.6 检索出处可见：没有命中就不出标注

本地知识库走 BM25 + 向量的混合检索。每轮答复若命中库内片段，后端下发 `sources` 事件、前端渲染「参考来源」卡片，标题与出处可点验；**没有命中就不出标注**，不做「看起来有出处」的假标注。回归 `test_rag_sources.py` 38 项 实测 。如实说明：混合检索已在请求路径接线，当前面板状态为 `wired_idle`（不称「已命中」）。

3.7 成本可控：真实计量 + 前缀缓存 + 生图指纹复用

成本由测量脚本打本机真实接口、每场景前后各读一次计量取差值得到，**不按公开单价推算**。两项实测有效的降本机制：① **提示词前缀稳定化**——分钟级时钟、IP 定位、Skill 正文这类每轮都变的值一律移到末尾，头部逐字不动，使后续轮次命中上游上下文缓存，输入 token 中 37.3% 按命中价计费；② **生图参数指纹复用**——model / size / prompt 规范化后取 sha256 作指纹，命中即复用已落盘图片、不发网络请求，同一张图不付第二次钱。模型单价只走环境变量；未配置时只报 token 不报金额。



这意味着第 N 轮请求不会因为历史变长而线性涨价，费用与延迟因此可预期 实测 。

3.8 模型层：运行期热切换 + 两级容错

国产大模型的可用性会变（限流、调价、欠费、接口调整），因此模型不写成编译期依赖： DeepSeek / 智谱 / 通义 / Kimi 经 `/api/config` 与 `/api/providers` 运行期热切换， 默认 `deepseek-chat`，配置目录不进提交包。发送层另加退避重试 （1 次、1.5s 退避，只对 timeout / network / busy / server 四类可重试错误生效）与备用通道 （`SMARTTOURISM_LLM_FALLBACK_BASE_URL / _KEY / _MODEL`）——主通道故障时改道，而不是把错误直接抛给用户。 非流式 120s、流式 180s，流式另有看门狗，超时按中断处理并保留已生成部分。

数据侧与生图侧同样按「会失败」设计：美团接口 timeout 30s、结果缓存 TTL 300s、stale 上限 24h（实测上游 11–44s）， 故障时回退最近一次成功数据并在提示词里标明「这是多久前的数据、仅供参考」，**绝不拿旧价假装实时价**； 高德按锁 + 最小间隔 0.16s + 3 次尝试封装限流；生图统一走火山方舟 Seedream，带参数自适应重试与 「场景 Key 欠费回落共享 Key」两级容错，并把生图 150s / 拉图 60s / 前端 abort 215s 对齐， 修掉「上游已计费、本地先放弃」的错位。这一层的回归为 `test_llm_retry` 57 项、 `test_dao_guard` 40 项、 `test_hotpath_degrade` 39 项、 `test_concurrency` 22 项 实测 。

3.9 AI Coding 开发实践：AI 起草，人做主

本项目用 AI Coding 完成主要编码，但质量不以生成代码量、对话轮次或 token 消耗计，而以「理解代码、能验证、能维护」为准。 下面四类缺陷都不是编译或接口自检发现的，而是人工回溯调用链、逐段审查与校对报告时发现的。

表 3-1　人工审查发现的典型缺陷与处置

缺陷	为何自检漏过	处置与教训
新路由插在 Flask 路由函数体中间，原路由静默失效	`py_compile` 通过，接口也未报错	编译通过 ≠ 路由存在；改为核对 `@app.route` 函数边界并逐条统计路径
「建了 15 个 Agent 模块」容易被讲成「上线了 15 项能力」	模块都能 import、单测都过，但没进请求路径	接线状态做成面板可观测的 `wired / unwired` 计数；能力清单以请求路径为准，不以 import 过为准
成本章节用「估算」写得像实测	估算口径本身合理，但读者会当结论用	改为测量脚本打本机真实接口、逐场景采 usage，整章换成【实测】；单价移出代码走环境变量
示例 API Key 以字面量写在源码里	清洁化正则没覆盖「裸 32 位十六进制」，当时的「敏感信息 0 残留」是假的	字面量移出源码、只存 sha256 指纹；自检补特征并对命中值掩码预览；新增 47 项凭据用例锁住这条线

另一处分工也能说明同一件事：上下文模块 AI 给出的是分层记忆通用方案（引入分词器与向量库）， 人工按本项目「零第三方依赖」的约束改为保守近似（CJK 每字≈1、其余 len/4，宁可高估不超发）加「最近 4 轮无条件必保」。

4 实用性与落地验证

本章按界面入口逐页展开：每一项约束、每一类客群策略、每一份产出的构成，都取界面与源码里的原文， 不写「智能规划、个性推荐」这类无法追问的概括词。

4.1 功能总览：六个界面入口

表 4-1 界面入口 · 界面上做得出来的事 · 已接线的后端接口

入口	界面上做得出来的事	已接线的后端接口
首页	热门灵感橱窗六张卡与详情弹层、今日运营看板三张 KPI、实时热点机会 TOP 10、四条能力入口	`/api/portal/hot-showcase` · `/api/portal/hot-reviews` · `/api/ops/dashboard`
对话	多会话并行、流式答复、停止生成、重新生成与编辑重发、点赞点踩、语音输入、参考来源与结尾推荐卡片	`/api/chat` · `/api/chat/stop` · `/api/feedback` · `/api/sessions` · `/api/recommend/cards`
规划	十二项约束一次填清、缺要素先追问、按意见就地重规划、十一部分完整行程、推荐卡片与地图导航、保存与导出	`/api/plan` · `/api/recommend/cards` · `/api/map/poi-search` · `/api/user/booking`
营销	六类内容一键生成、内容板逐块取舍、文创灵感库、数字名片与二维码、AI 概念海报与同图复用	`/api/marketing` · `/api/creative` · `/api/cards` · `/api/ark/generate`
社区	攻略笔记流与详情、四维筛选（平台 / 城市 / 主题 / 人群）、主题灵感与社区精选、点击率与收藏排行	`/api/xhs/notes` · `/api/market/hot-inspirations` · `/api/social/hotspots`
我的	登录注册与图形验证码、三条内容链路（行程 / 营销内容 / 保存的攻略）、整包数据导出	`/api/auth/captcha` · `/api/user/profile` · `/api/export/mine`

6 个视图
顶部导航即可点开的六个入口

85 条路径
服务端唯一 REST 路径

17 张表
SQLite 本机建表脚本

4 个独立页
地图 · 名片 · 移动端 · 面板

六个视图之外，还有四个由服务端路由直接托出的独立页： `/map` 全屏地图、 `digital-card.html` 名片落地页、 `/m` 移动端、 `/admin` 运维面板。 功能边界如实分开：社区发布与攻略收藏只写在这台浏览器的本地存储，不称其入库，社区也只有收藏、没有点赞； `/api/tickets` 、 `/api/stats` 、 `/api/match` 等接口没有界面入口；拍照识景未做。 口径：以 `dashboard/index.html` 的六个 `data-page` 视图与前端实际调用点为准 实测 。

4.2 规划：能针对哪些人群、能设哪些约束、能交付什么

规划页把出行条件一次问清，缺关键项先追问再动笔；出稿后不只是一张观光清单，还带着消费触点与可当场执行的后续动作。

表 4-2　规划功能的输入、产出与后续动作

环节	能力范围
可针对的人群	情侣/伴侣、亲子家庭、朋友/闺蜜、银发同行、商务差旅、团建团队、独自旅行七类同行关系；每类在策略库里各有景点、住宿、餐饮、节奏与消费触点的成文取值，换人群换的是行程结构而不是措辞 实测
可设的约束	十二项：目的地城市、出行天数、预算档、同行关系、消费倾向、路线节奏、出行方式，两组多选（偏好标签、行为画像），三项自由文本（多人偏好差异、重点促进消费、不想要 / 特殊需求）；目的地、天数、同行关系为必填，缺项返回澄清清单并声明可先出一版草案
交付的产出	一次输出十一个部分：画像与冲突、假设与数据来源、行程总览、每日安排、偏好平衡、消费转化、文创伴手礼、三档预算、异常与替代路线、适配理由、地图路线；直接可读的排在前面，依据类可展开
价格与时间口径	美团票价与住宿价、高德天气在生成前采集并优先采用；取不到实时数据时明写「暂未获取到实时数据」，模型推断值一律标注来源，禁止不标来源直接输出价格
生成之后	按意见就地重规划（不重填条件）、保存到个人行程、导出文本与手账、分享、按路线生成推荐卡片、地图导航与地名点击联动

① 填写条件
12 项约束一次问清
→
② 缺项澄清
必填缺失先追问
→
③ 实时采集
票价 · 住宿价 · 天气
→
④ 分段出稿
11 个部分流式生成
→
⑤ 后续动作
重规划 · 保存 · 导出

7 类人群
同行关系各有成文策略

12 项约束
三项必填，缺项先追问

11 个部分
缺一个部分就算残缺

6 类动作
从重规划到地图导航

4.3 对话：十项答复控制与结尾推荐

对话页首屏给六个快捷场景与四条示例提问，输入框限 4,000 字、Enter 发送；答复控制一共十项，逐项都不是摆设：

表 4-3　对话页可用的十项控制

控制	界面上的具体行为
新建对话	「+」开新会话；历史会话一条都不动（此约束写成 76 项断言）
历史对话	「🕘」列出会话，支持重命名与删除；服务端列表按用户隔离，本机留档上限 30 会话 × 60 条
停止生成	「■ 停止」真停上游流并释放线程，半截答复标注「这条答复被手动停止，内容不完整」后落库
重新生成	「🔄」只撤回这一轮并重发，比对不上就不删，避免误删历史
编辑重发	「✎」把原始提问放回输入框，改后重发
点赞 / 点踩	「👍 有用」「👎 不对」落库，点踩再选原因（没答到点上 / 信息不准确 / 太啰嗦），回放时投票状态不丢
参考来源	「📚 参考来源（N）· 本地知识库检索」逐条列出命中片段与相关度百分比；没有命中就不出标注，不装成检索过
语音输入	「🎤」录音并转写，显示「正在录音，请说话…」；上游不可用时给中文可读原因，不甩原始报错
上下文水位	「🧩 上下文」进度条显示本会话 token 占用，到 75% 触发线自动压缩早期轮次为摘要
定位与修正	进入对话即尝试定位并显示「定位中…」，可点「修正」手工改城市、「重新定位」再取一次——城市决定后续推荐与天气口径

6 个场景
行程规划 / 酒店推荐 / 美食探索 / 营销文案 / 亲子出游 / 文创伴手礼

4,000 字
单条输入长度上限

30 × 60
本机留档：会话数 × 每会话消息数

75%
上下文占用触发自动压缩的水位线

每条答复结尾挂一段推荐面板：景点 / 美食 / 酒店三组，标注数据优先级，默认先露 3 张， 同一城市的聚合结果做缓存不重复付费 实测 。

4.4 营销：六类内容、内容板与数字名片

营销页左侧是完整的条件表单，出稿前把「给谁看、在哪发、促什么」都问清楚。

表 4-4　营销生成表单的可选值（界面原文）

字段	可选值
内容类型	社交媒体文案 / 公众号推文 / 短视频脚本 / 海报文案 / 活动策划 / 文创产品概念——每类的成文结构单独规定，短视频脚本要求前 3 秒制造停留，不搞一类模板套六样
目标客群	自动识别 / 亲子家庭 / 情侣蜜月 / 银发一族 / 公司团建 / 大学生 / 商务出差
风格调性	时尚潮流 / 文艺清新 / 幽默风趣 / 专业深度 / 温暖治愈
目的地 / 产品	文本，界面示例「杭州西湖」——决定文案写的是地点还是具体单品
主推产品 / 产品线	文本，示例「夜游船票 + 双人下午茶 + 香囊礼盒」，把「这篇推什么」写成条件而不是让模型猜
投放渠道	文本，示例「小红书、抖音、公众号、OTA」，决定成文的平台适配版本
经营目标 / 转化目标	两项文本：前者示例「提升七夕情侣套餐预订与文创加购」，后者示例「购票、预约、到店、文创加购」——一个管要什么结果，一个管希望用户当场做哪个动作
补充说明	自由文本，用于写清卖点、特色与限制
海报开关	勾选框「同时为形象款文创生成 AI 概念海报（需配置火山方舟 API Key）」，只在选中特定内容类型时才出现
同页子面板	旅游推广博客生成（五种博客风格、五类目标读者）与文创灵感库（国潮 / 非遗 / 博物馆 / 文创 IP / 节庆 / 景区特产，可「提取灵感填充营销」）

出稿后有「内容板」逐块取舍：每段可保存 / 修改 / 丢弃，处理完再复制全部已保存内容；留档按用户存在本机，上限 30 条， 可在「我的 · 我的营销内容」回看。只有「文创产品概念」这一类会出「转化为数字名片」按钮——名片页带二维码与七个板块， 印到包装上即扫码直达。勾选后另走 AI 概念海报生图，同一张图命中指纹时不重复计费 实测 。

合规口径写在提示词与能力规格里（分平台的成文结构、广告法极限词约束），运行时由输出护栏对绝对化用语做检查并计入面板指标；界面上没有独立的「合规检查」按钮，不把它说成一键功能。

4.5 首页、社区与我的：把容易被夸大的地方写明白

表 4-5　三个入口界面上具体有什么、数据从哪来

入口	界面上具体有什么	数据来源与留档口径
首页	热门灵感橱窗六张卡（景点 / 文创 / 餐食 / 夜游 / 住宿 / 非遗市集）与详情弹层，今日运营看板三张 KPI 卡，实时热点机会 TOP 10，今日建议任务，四条能力入口	看板走 `/api/ops/dashboard` 聚合热点、灵感库与票务；KPI 值（目的地热度 / 咨询转化 / 内容机会）按公式算出，是相对量而非转化率实测；橱窗首屏文案为内置示例，评价流由 `/api/portal/hot-reviews` 异步替换为真实平台评价
社区	攻略笔记流与详情页、平台 / 城市 / 主题 / 人群四维筛选与搜索、主题灵感与社区精选、点击率排行与收藏排行、「发布旅游心得」表单（标题 / 标签 / 正文三项）	笔记流来自 `/api/xhs/notes`（灵感库真实落库，只存公开入口、摘要与标签，完整内容跳转原平台），热点更新走 `/api/market/hot-inspirations`；首屏四条为内置示例，用户发布与收藏只写本机 localStorage，不入库、无点赞
我的	三条内容链路：我的行程、我的营销内容、我保存的攻略，底部一键「导出我的全部数据」，删除前逐条二次确认	行程读 SQLite 并可删（带所有权校验）；营销留档与收藏攻略来自本机存储，导出时一并合并进同一个 JSON 文件，文件名带日期，导出后提示会话 / 消息 / 行程 / 本地留档各多少条
登录	顶部导航「登录」弹层：登录 / 注册两个页签、账号密码与 4 位图形验证码（点图可刷新），登录状态一句话写明「已登录 · 数据仅本机保存」	验证码走 `/api/auth/captcha`，令牌存本机；未登录也能完整使用，只是专属行程与收藏不落地——把游客态做成可用态，而不是拦在门外

6 张橱窗卡
景点 / 文创 / 餐食 / 夜游 / 住宿 / 非遗，点击进详情

3 张 KPI 卡
目的地热度 / 咨询转化 / 内容机会，公式相对量

4 维筛选
平台 / 城市 / 主题 / 人群，附搜索与排行

1 个文件
整包导出：会话、消息、行程、本机留档

「内置示例」「公式计算的看板值」「只写本机的留档」这三件事最容易被说成实时数据与真实转化率，这里把口径摊开，可在同一页对着网络请求逐条核对哪一句成立 实测。

4.6 工程规模与质量

表 4-6　规模、质量与实测口径（数值取自源码逐文件统计与全量回归）

指标	数值	口径与复现方式
服务端规模	63 个文件 · 30,005 行	递归统计 `server/*.py`；其中测试 9,689 行，业务实现约 20,316 行
接口与数据	85 条唯一 REST 路径 · 17 张数据表	对 `@app.route` 声明逐条统计（91 个声明按方法拆分）；表结构见 SQLite 建表脚本
插件与 Skill	7 个插件 · 3 个 Skill · 6 类画像	`plugins/` 统一继承 BasePlugin；`skills/` 按 SKILL.md 规范组织
自动化回归	36 个测试文件 · 1,716 项断言全绿	`python run_tests.py`，实测于 2026-10-05
前端形态	零框架单页 10,440 行	`dashboard/index.html`，唯一外链为本地脚本
运行依赖	4 核心 + 4 可选，最小启动集 3	按 `requirements.txt` 逐行标注
作品材料	介绍 PPT 35 页 · 报告 34 页 + 精简版 21 页	由 `make_report.py` 与 `_deck/_build.py` 生成，可当场重印
红线自检	敏感信息 0 残留 · 参赛规范 0 命中	`prepare_submission.py` 排除本机产物与配置目录后做特征扫描

4.7 部署与运行：现场可当场验证

双击 `start.bat` 即以 waitress 生产级 WSGI 起服务（监听 `127.0.0.1:5050`），浏览器打开即为完整应用，无需构建前端与数据库服务；**不配置任何模型 Key 时不白屏**，降级为本地知识库兜底并给中文可读原因，断网与欠费场景都实测过 实测。`/admin` 面板实时显示模型用量、缓存命中、生图张数与复用率、答复质量与降级计数，带阈值告警。

4.8 测试怎么组织：按主题分文件，断言只打真实行为

36 个测试文件按主题拆分而非按代码目录镜像，每个文件对应一条能被当场追问的能力，跑在子进程里隔离； 断言只打**可观测的真实行为**——落库字段、SSE 事件序列、面板计数、响应结构，不打内部实现。 「新建对话绝不能删除历史会话」这条来自真实事故的约束写在 `test_session_management` 里，`test_secret_hygiene` 47 项把「源码里不许出现裸 Key」锁成一条会失败的测试。

4.9 量级对照：只给口径，不给百分比

AI 侧耗时是打真实接口计时的 实测，人工侧基线是本项目的 经验估计。 两者并排只为了让量级可感，**本项目未做人工对照实验，因此不给「效率提升 N%」这类结论。**

表 4-7　同类任务量级对照

任务	人工基线	本系统
一条 3 天行程（含票价、路线、雨天替代）	2–4 小时 / 份	50.03s · 输出 1,444 字
一篇平台化营销文案（含合规检查）	1–2 小时 / 篇	6.66s · 首字 1.21s · 成文 1,227 字

人工基线口径：按单人查攻略、核对营业时间与多平台排版估时，未做对照实验，故只作数量级参考，不作结论 预期。

表 4-8　回归按主题分布（项数为所列各测试文件的断言数，取自 `python run_tests.py` 逐文件输出）

主题	测试文件（项数）	覆盖点
对话控制	session_management(76) · stream_stop(71) · regenerate(44) · feedback_metrics(112)	会话隔离、真停、只撤一轮
真实性与出处	validation_degrade(42) · rag_sources(38)	闸口、降级、出处标注
成本与计量	llm_usage(55) · prompt_cache(42) · image_cost(71)	usage、命中、生图复用
稳健性与并发	llm_retry(57) · dao_guard(40) · hotpath_degrade(39) · concurrency(22) · meituan_cache(114)	重试与备用通道、护栏
业务与界面	profile_center(78) · portal_showcase(57) · data_export(50) · ops_log(60) · secret_hygiene(47)	栏目、导出、凭据自检
其余两组	context_manager(57) · memory(79)；另有 Agent 能力库 11 个文件（tools / graph / multi_agent / hitl / mcp_server / tracing / structured_output / graphrag / model_router / evaluation / agent_modules）	上下文与记忆 136 项、Agent 能力库 317 项；七组合计 1,716 项 / 36 个文件 / 0 失败

4.10 数据主权与可交付性

全部数据仅存本机：结构化数据在 SQLite，前端状态按用户命名空间存 localStorage，`/api/export/mine` 一键导出整包；个人中心只保留三条能追到库里数据的链路，没有真实数据来源的「订单 / 酒店 / 机票」入口一律不做。

17 张表
SQLite 本机持久化：账号与令牌、会话与记忆、行程、营销内容、反馈与运维计数

按用户隔离
前端状态存 localStorage 的用户命名空间，不跨账号串数据

一条命令
整包导出：行程、会话、收藏、营销内容、反馈，数据跟着人走

表 4-9　17 张数据表按用途分布（取自 SQLite 建表脚本）

用途	表名	承接的功能
账号与会话	`users` · `auth_tokens` · `sessions` · `messages` · `session_state` · `memories` · `message_feedback`	登录、多会话、上下文与反馈
行程与内容	`itineraries` · `marketing_contents` · `user_store`	我的行程、营销留档、消费触点
数据与素材源	`travel_cities` · `travel_pois` · `xhs_notes` · `imported_sources`	本地知识库兜底、社区笔记
运维与成本	`operation_logs` · `coupon_claims` · `ark_image_cache`	调用留痕、生图指纹复用

4.11 实用性判断：三条能证成，三条不承诺

- **能证成**：产出可直接使用（行程含开放时间、票价来源标注、购票深链与替代路线；文案含平台适配与合规口径）。
- **能证成**：成本与延迟可预期（输入预算硬上限 + 缓存命中实测 + 生图不重复计费）。
- **能证成**：出错可追（每次调用留痕、降级进面板计数、回归覆盖到具体文件与项数）。
- **不承诺**：转化率与获客收益、人工替代比例、商业化收入——这三类需对照实验或真实投放数据，未做，故不给数字。

三条「能证成」各有当场可走的验证路径：票价与深链看 `/api/plan` 返回、token 与缓存命中看 `/api/admin/ops`、留痕看 `operation_logs`；三条「不承诺」写进限制而不是写进亮点。

5 已知边界与复现方式

5.1 已知限制

- **首字延迟偏高**：行程场景首字 40.99s，因前置采集（定位 / 实时数据 / 检索）在生成之前。 是否改为流式优先属产品决策，当前未实现，不粉饰为已优化。
- **生图依赖上游账户额度**：欠费时出图直接失败，系统回退占位图并写明原因、可重试，不假称成功。
- **混合检索当前为空闲状态**：已在请求路径接线，但面板实例未触发索引构建，故标注为空闲而非已命中。
- **成本样本量有限**：实测成本来自 4 个场景 7 次调用的单次进程累计，代表「这一遍跑出来的量」，不是大样本统计。
- **无交易闭环**：只提供官方购票深链，不代下单、不接支付，无法声称闭环成交能力。
- **多人偏好平衡靠规则承接**：同行人群含多种偏好时，由提示词规则与固定输出模块处理，未实现独立的偏好求解算法。
- **校验层只证来源、不证对错**：`validation` 覆盖绝对化用语、无来源价格与编造图片链接， 词表与正则的覆盖始终有限，故其通过率只当过程计数，不当质量结论。
- **单文件体量偏大**：`app.py` 7,684 行、前端单页 10,440 行，可读性与可维护性是明确技术债，列为后续拆分项。

5.2 数据口径约定

全文数字分三类并逐条标注：**实测**——由脚本或面板读自真实运行系统，附复现命令； **估算**——口径公开可复核；**预期**——尚未验证的目标或经验基线， 尤其是人工耗时对照，只作假设不作结论。三类不混用、不互相冒充。

实测
读自运行中的系统：回归项数、面板计数、逐场景 token 与延迟，均可一条命令复现

估算
口径公开可复核，如按字与按调用次数的保守折算，只用于比较不用于结论

预期
尚未验证的目标与经验基线，如人工耗时对照，写在限制里而不是亮点里

本页三类标签的样本口径：【实测】数字来自同一台 Windows 本机的单次进程累计， 换机器、换上游账户或改模型配置后应重跑 5.3 的命令取新数，不沿用本页数值作结论。

5.3 复现命令

```
# 1) 起服务（监听 127.0.0.1:5050）
start.bat    # 或 python server\run_server.py

# 2) 全量回归：36 个测试文件 / 1,716 项断言
python run_tests.py

# 3) 逐场景实测 token 与延迟（差值归场景）
python server\measure_llm_cost.py

# 4) 实时累计值（模型用量 / 缓存命中 / 生图复用率 / 答复质量）
curl http://127.0.0.1:5050/api/admin/ops    或打开 /admin 面板

# 5) 未接线模块的离线运行记录（11 ok / 0 failed）
python server\agent_offline_demo.py
```

5.4 下一步：按「能否写成一条会失败的测试」排序

待办不按想法大小排，按两条硬判准排：这条需求能否追到一个真实数据源，能否写成一条会失败的测试；两条缺一，就留在待办里而不是界面上。 排在前面的三项都来自本章列出的限制本身。**第一，把校验从规则升级成带上下文的判定**—— 现在 `validation` 能证明的是「这句话有没有来源、有没有踩到已知违规表达」，不能证明「这句话是对的」， 这条改完才能把通过率当质量信号用。

第二，把大文件拆开： `app.py` 与前端单页的拆分方案已定（按接口域切 blueprint、前端按视图分模块）， 但它不新增能力，因此排在真实能力之后而不是之前。**第三，多人偏好平衡**：把当前靠提示词规则承接的部分， 改成有明确输入输出、可被测试覆盖的求解步骤。

5.5 结语

三件事都能被上面这些命令当场验证：**让一条行程真的能出发**——带的是实时核对过的价格与路线；**让一张名片真的能带客**——产出物本身就是扫码入口；**让每一次模型调用算得清、查得到出处**——token 来自真实响应，数据来自可核验接口，没做到的写在限制里而不是藏在形容词里。